

# ¿Qué sectores pagan más? Compensación ejecutiva ajustada por tamaño

Archivo `07. T1_GC_datos.xlsx`, año fiscal 2023. Tres columnas de compensación del archivo:

| Columna | Variable                                       | Contenido                                    |
|---------|------------------------------------------------|----------------------------------------------|
| AT      | Total Compensation Paid to Executives          | Suma pagada a todo el equipo ejecutivo (USD) |
| AU      | Total Compensation Paid to CEO and Equivalent  | Solo el CEO (USD)                            |
| AV      | Total Board of Director Compensation Paid      | Junta directiva (USD)                        |
| AW      | Number of CEO and Equivalent Changes During FY | Cambios de CEO en el año                     |

**Nota sobre las columnas pedidas.** AW no es una variable de compensación sino de rotación del CEO. Se conserva, pero como variable de corte en la sección 6: sirve para separar el pago recurrente del pago de salida. Se agrega AU porque sin ella no se puede distinguir cuánto del paquete ejecutivo se concentra en una sola persona.

**El problema central.** El nivel absoluto de compensación mide sobre todo el tamaño de la empresa. Comparar el pago mediano de Tecnología contra el de Servicios Públicos sin corregir por tamaño responde a la pregunta equivocada. Aquí se normaliza de dos formas:

1. **Razones simples:** pago por cada USD 1.000 millones de ingresos, por empleado, y en puntos básicos de capitalización bursátil.
2. **Regresión log-log con efectos de sector:**  $\log(\text{pago}) \sim \log(\text{tamaño}) + \text{sector}$ . El coeficiente del sector es la **prima**: cuánto paga de más o de menos ese sector frente a lo que su tamaño predice.

## 1. Carga y construcción de variables

```
In [1]: import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import statsmodels.formula.api as smf

pd.set_option("display.max_columns", 60)
pd.set_option("display.width", 200)
pd.set_option("display.float_format", lambda x: f"{x:,.2f}")
```

```

plt.rcParams["figure.figsize"] = (11, 6)
plt.rcParams["axes.grid"] = True
plt.rcParams["grid.alpha"] = 0.3

df = pd.read_excel("07. T1_GC_datos.xlsx", sheet_name="datos")
df = df.drop(columns=[c for c in df.columns if c.endswith(".1")]) # duplica

RENOMBRES = {
    "Industry Sector": "Sector",
    "Total Compensation Paid to Executives": "CompEjec", # AT
    "Total Compensation Paid to CEO and Equivalent": "CompCEO", # AU
    "Total Board of Director Compensation Paid": "CompJunta", # AV
    "Number of CEO and Equivalent Changes During FY": "CambiosCEO", # AW
    "Number of Directors Included Compensation Paid": "NDirPagados",
    "Number of Employees": "Empleados",
    "Revenue": "Ingresos",
    "Total Assets": "Activos",
    "Current Market Cap": "MCAP",
    "Return on Assets": "ROA",
    "Operating Margin": "MargenOp",
    "BESG Governance Pillar Score": "G",
}
df = df.rename(columns=RENOMBRES)

# Unidades del archivo: Ingresos, Activos y EBITDA vienen en millones de USD
# MCAP y las tres columnas de compensación vienen en USD. Se homogeneiza a L
for c in ["Ingresos", "Activos"]:
    df[c + "_usd"] = df[c] * 1e6

print(f"Filas: {len(df):,} Sectores: {df['Sector'].nunique()}")
df[["Ticker", "Sector", "CompEjec", "CompCEO", "CompJunta", "CambiosCEO"]].f

```

Filas: 1,878      Sectores: 10

| Out[1]: | Ticker                | Sector         | CompEjec       | CompCEO       | CompJunta    | CambiosCEO |
|---------|-----------------------|----------------|----------------|---------------|--------------|------------|
| 0       | AAPL<br>US<br>Equity  | Technology     | 183,325,385.00 | 74,609,802.00 | 3,099,264.00 | 0.00       |
| 1       | MSFT<br>US<br>Equity  | Technology     | 163,430,212.00 | 79,106,183.00 | 4,230,000.00 | 0.00       |
| 2       | NVDA<br>US<br>Equity  | Technology     | 83,157,547.00  | 34,167,902.00 | 4,892,588.00 | 0.00       |
| 3       | AMZN<br>US<br>Equity  | Communications | 4,600,271.00   | 1,357,764.00  | 4,514,830.00 | 0.00       |
| 4       | GOOGL<br>US<br>Equity | Communications | 147,396,768.00 | 8,802,824.00  | 3,627,134.00 | 0.00       |

## 1.1 Cobertura: el sector *Funds* no tiene datos de compensación

383 de las 1.878 filas son fondos cotizados. No tienen ejecutivos, ingresos ni empleados en el sentido del resto de la muestra y su compensación está vacía en el 100% de los casos. Se excluyen: dejarlos dentro solo mete ceros y NaN en cada agrupación.

```
In [2]: cobertura = (
    df.groupby("Sector")["CompEjec", "CompCEO", "CompJunta", "Ingresos", "Empleados"]
    .apply(lambda d: d.notna().sum())
    .assign(filas=df["Sector"].value_counts())
)
cobertura["pct_CompEjec"] = (100 * cobertura["CompEjec"] / cobertura["filas"])
print(cobertura.sort_values("filas", ascending=False).to_string())

d = df[df["Sector"] != "Funds"].copy()
print(f"\nMuestra de trabajo: {len(d):,} empresas operativas, "
      f"{d['CompEjec'].notna().sum():,} con dato de compensación ejecutiva "
      f"({100 * d['CompEjec'].notna().mean():.0f}%).")
```

|                        |              | CompEjec | CompCEO | CompJunta | Ingresos | Empleados | filas |
|------------------------|--------------|----------|---------|-----------|----------|-----------|-------|
| filas                  | pct_CompEjec |          |         |           |          |           |       |
| Sector                 |              |          |         |           |          |           |       |
| Funds                  |              | 0        | 0       | 0         | 0        | 0         | 383   |
|                        | 0.00         |          |         |           |          |           |       |
| Financial              |              | 299      | 293     | 303       | 311      | 301       | 312   |
|                        | 95.80        |          |         |           |          |           |       |
| Consumer, Non-cyclical |              | 278      | 271     | 281       | 294      | 288       | 295   |
|                        | 94.20        |          |         |           |          |           |       |
| Industrial             |              | 207      | 206     | 208       | 214      | 205       | 215   |
|                        | 96.30        |          |         |           |          |           |       |
| Consumer, Cyclical     |              | 184      | 180     | 184       | 199      | 190       | 200   |
|                        | 92.00        |          |         |           |          |           |       |
| Technology             |              | 173      | 169     | 171       | 193      | 175       | 193   |
|                        | 89.60        |          |         |           |          |           |       |
| Communications         |              | 86       | 76      | 81        | 99       | 94        | 99    |
|                        | 86.90        |          |         |           |          |           |       |
| Energy                 |              | 70       | 69      | 71        | 76       | 71        | 76    |
|                        | 92.10        |          |         |           |          |           |       |
| Utilities              |              | 52       | 52      | 53        | 57       | 53        | 57    |
|                        | 91.20        |          |         |           |          |           |       |
| Basic Materials        |              | 47       | 47      | 47        | 48       | 48        | 48    |
|                        | 97.90        |          |         |           |          |           |       |

Muestra de trabajo: 1,495 empresas operativas, 1,396 con dato de compensación ejecutiva (93%).

La cobertura de las tres columnas de compensación es del 90% dentro de las empresas operativas y es pareja entre sectores. Ese es el punto importante: la comparación entre sectores no está contaminada por diferencias de reporte.

## 2. Nivel absoluto: la respuesta equivocada

```
In [3]: COMP = ["CompEjec", "CompCEO", "CompJunta"]

nivel = d.groupby("Sector")[COMP].median()
```

```
nivel["n"] = d.groupby("Sector")["CompEjec"].count()
nivel = nivel.sort_values("CompEjec", ascending=False)
print("Mediana de compensación por sector (USD):")
nivel
```

Mediana de compensación por sector (USD):

Out [3]:

|                        | CompEjec      | CompCEO       | CompJunta    | n   |
|------------------------|---------------|---------------|--------------|-----|
| Sector                 |               |               |              |     |
| Communications         | 33,163,728.00 | 14,882,119.00 | 2,728,879.00 | 86  |
| Technology             | 32,480,316.00 | 13,405,690.00 | 2,445,000.00 | 173 |
| Consumer, Cyclical     | 26,903,574.00 | 11,639,330.50 | 2,563,357.00 | 184 |
| Energy                 | 26,304,792.50 | 11,254,921.00 | 2,480,405.00 | 70  |
| Basic Materials        | 26,214,832.00 | 11,881,204.00 | 2,851,421.00 | 47  |
| Consumer, Non-cyclical | 25,677,129.00 | 11,650,671.00 | 2,915,955.00 | 278 |
| Financial              | 23,500,617.00 | 9,479,687.00  | 2,357,113.00 | 299 |
| Industrial             | 20,899,886.00 | 9,321,739.50  | 2,407,500.50 | 207 |
| Utilities              | 20,557,971.00 | 8,831,298.50  | 2,690,908.00 | 52  |

In [4]:

```
tam = d.groupby("Sector")["Ingresos", "MCAP", "Empleados"].median()
tam["MCAP_bn"] = tam["MCAP"] / 1e9
comparacion = nivel["CompEjec"].join(tam["Ingresos", "MCAP_bn", "Empleados"])

print("Compensación ejecutiva mediana vs. tamaño mediano del sector:")
print(comparacion.to_string())

# La correlación relevante es a nivel de empresa, no de mediana sectorial (9
sub = d[["CompEjec", "MCAP", "Ingresos", "Empleados"]].dropna()
print("\nSpearman a nivel empresa entre compensación ejecutiva y tamaño:")
for v in ["MCAP", "Ingresos", "Empleados"]:
    print(f" {v:10s} rho = {sub['CompEjec'].corr(sub[v], method='spearman')}")

rho_sec = comparacion["CompEjec"].corr(comparacion["MCAP_bn"], method="spearman")
print(f"\nSpearman entre medianas sectoriales (CompEjec, MCAP) = {rho_sec:+.4f}")
    "→ con 9 puntos y Utilities como caso atípico, la mediana sectorial no
```

Compensación ejecutiva mediana vs. tamaño mediano del sector:

|                        | CompEjec      | Ingresos | MCAP_bn | Empleados |
|------------------------|---------------|----------|---------|-----------|
| Sector                 |               |          |         |           |
| Communications         | 33,163,728.00 | 7,039.59 | 15.36   | 9,328.50  |
| Technology             | 32,480,316.00 | 2,207.10 | 10.12   | 6,450.00  |
| Consumer, Cyclical     | 26,903,574.00 | 6,702.00 | 8.12    | 15,000.00 |
| Energy                 | 26,304,792.50 | 5,103.77 | 8.83    | 2,300.00  |
| Basic Materials        | 26,214,832.00 | 8,653.99 | 8.32    | 13,471.50 |
| Consumer, Non-cyclical | 25,677,129.00 | 3,801.62 | 8.73    | 10,200.00 |
| Financial              | 23,500,617.00 | 2,987.31 | 7.89    | 3,168.00  |
| Industrial             | 20,899,886.00 | 4,596.40 | 8.27    | 14,000.00 |
| Utilities              | 20,557,971.00 | 5,455.10 | 16.24   | 6,403.00  |

Spearman a nivel empresa entre compensación ejecutiva y tamaño:

MCAP rho = +0.575 (n = 1,363)  
Ingresos rho = +0.542 (n = 1,363)  
Empleados rho = +0.447 (n = 1,363)

Spearman entre medianas sectoriales (CompEjec, MCAP) = +0.18 → con 9 puntos y Utilities como caso atípico, la mediana sectorial no informa.

Comunicaciones y Tecnología encabezan la tabla en nivel absoluto. A nivel de empresa, la compensación ejecutiva correlaciona fuerte con las tres medidas de tamaño (rho de Spearman entre +0,45 y +0,58): **la mayor parte de la variación del pago es variación de tamaño.**

La correlación entre medianas sectoriales es baja, pero eso no contradice lo anterior: son solo nueve puntos y Servicios Públicos los rompe, porque tiene la capitalización mediana más alta de la muestra y el pago mediano más bajo. Ese sector es exactamente el que hay que explicar, y para eso hace falta el ajuste por tamaño a nivel empresa.

### 3. Normalización 1: razones simples

Tres denominadores, tres preguntas distintas:

- **Por cada USD 1.000 M de ingresos** — cuánto cuesta la cúpula frente a la escala del negocio.
- **Por empleado** — cuánto pesa la cúpula frente a la nómina que dirige.
- **En puntos básicos del *market cap*** — cuánto cuesta la cúpula al accionista.

Ninguna es neutral. Un banco tiene pocos ingresos contables y muchos activos; una petrolera tiene ingresos enormes y poca gente. Por eso se reportan las tres.

```
In [5]: d["Comp_por_1000M_ing"] = d["CompEjec"] / (d["Ingresos_usd"] / 1e9)
d["Comp_por_empleado"] = d["CompEjec"] / d["Empleados"]
d["Comp_bps_MCAP"] = 1e4 * d["CompEjec"] / d["MCAP"]
d["CompJunta_por_dir"] = d["CompJunta"] / d["NDirPagados"]
d["CEO_sobre_ejec"] = d["CompCEO"] / d["CompEjec"]

RATIOS = ["Comp_por_1000M_ing", "Comp_por_empleado", "Comp_bps_MCAP"]
```

```
razones = d.groupby("Sector")[RATIOS].median()
razones["n"] = d.groupby("Sector")["CompEjec"].count()
print("Mediana por sector de las tres razones:")
razones.sort_values("Comp_bps_MCAP", ascending=False)
```

Mediana por sector de las tres razones:

Out [5]:

|                        | Comp_por_1000M_ing | Comp_por_empleado | Comp_bps_MCAP | n   |
|------------------------|--------------------|-------------------|---------------|-----|
| Sector                 |                    |                   |               |     |
| Basic Materials        | 3,093,074.74       | 2,141.80          | 25.52         | 47  |
| Consumer, Non-cyclical | 5,704,837.41       | 2,269.73          | 25.19         | 278 |
| Consumer, Cyclical     | 3,533,660.14       | 1,383.92          | 24.42         | 184 |
| Technology             | 14,408,899.95      | 5,113.79          | 22.59         | 173 |
| Financial              | 6,365,263.34       | 5,980.70          | 22.34         | 299 |
| Industrial             | 4,341,451.73       | 1,581.75          | 22.14         | 207 |
| Communications         | 4,612,567.13       | 3,252.79          | 20.45         | 86  |
| Energy                 | 3,689,994.40       | 9,883.40          | 19.93         | 70  |
| Utilities              | 3,859,351.42       | 4,073.96          | 12.62         | 52  |

In [6]:

```
# Ranking de cada sector bajo cada denominador (1 = paga más)
rank = razones[RATIOS].rank(ascending=False).astype(int)
rank["nivel_absoluto"] = nivel["CompEjec"].rank(ascending=False).astype(int)
rank = rank[["nivel_absoluto"] + RATIOS].sort_values("nivel_absoluto")
print("Posición del sector según el denominador que se use (1 = paga más):")
rank
```


Posición del sector según el denominador que se use (1 = paga más):

Out [6]:

|                               | nivel_absoluto | Comp_por_1000M_ing | Comp_por_empleado | Comp_t |
|-------------------------------|----------------|--------------------|-------------------|--------|
| <b>Sector</b>                 |                |                    |                   |        |
| <b>Communications</b>         | 1              | 4                  | 5                 |        |
| <b>Technology</b>             | 2              | 1                  | 3                 |        |
| <b>Consumer, Cyclical</b>     | 3              | 8                  | 9                 |        |
| <b>Energy</b>                 | 4              | 7                  | 1                 |        |
| <b>Basic Materials</b>        | 5              | 9                  | 7                 |        |
| <b>Consumer, Non-cyclical</b> | 6              | 3                  | 6                 |        |
| <b>Financial</b>              | 7              | 2                  | 2                 |        |
| <b>Industrial</b>             | 8              | 5                  | 8                 |        |
| <b>Utilities</b>              | 9              | 6                  | 4                 |        |

In [7]:

```
fig, axes = plt.subplots(1, 3, figsize=(16, 5.5), sharey=True)
titulos = {
    "Comp_por_1000M_ing": "USD por cada 1.000 M\nde ingresos",
    "Comp_por_empleado": "USD por empleado",
    "Comp_bps_MCAP": "Puntos básicos\ndel market cap",
}
orden = razones.sort_values("Comp_bps_MCAP").index
for ax, col in zip(axes, RATIOS):
    s = razones.loc[orden, col]
    ax.barh(s.index, s.values, color="#4C72B0")
    ax.set_title(titulos[col], fontsize=11)
    ax.grid(axis="y", alpha=0)
axes[0].set_xlabel("USD (millones)")
fig.suptitle("Compensación ejecutiva por sector: el ranking depende del denominador")
fig.tight_layout()
plt.show()
```



El ranking se reordena por completo según el denominador. Comunicaciones, primera en nivel absoluto, cae al cuarto, quinto y séptimo puesto. Tecnología es primera por ingresos, Energía es primera por empleado (pocas personas, mucho capital por cabeza)

y Materiales Básicos es primera en puntos básicos de *market cap* pese a ser novena por ingresos. Servicios Públicos es la última en costo para el accionista, con menos de la mitad de puntos básicos que el primero.

Las razones simples tienen un defecto: asumen que el pago escala **uno a uno** con el tamaño. No lo hace. Ese es el trabajo de la sección siguiente.

## 4. Normalización 2: la elasticidad del pago al tamaño

La relación empírica clásica es que la compensación crece con el tamaño, pero **menos que proporcionalmente**: duplicar la empresa no duplica el pago. Se estima

$$\log(\text{pago}) = \alpha + \beta_1 \log(\text{MCAP}) + \beta_2 \log(\text{Ingresos}) + \beta_3 \log(\text{Empleados}) + \varepsilon$$

Si  $\sum \beta < 1$ , dividir el pago por el tamaño (sección 3) **castiga mecánicamente a las empresas grandes** y por lo tanto a los sectores de empresas grandes.

```
In [8]: def winsorizar(s, p=0.01):
        """Recorta a los percentiles [p, 1-p]. Las colas de compensación son ext
        lo, hi = s.quantile([p, 1 - p])
        return s.clip(lo, hi)

        TAMANO = ["MCAP", "Ingresos_usd", "Empleados"]
        for c in COMP + TAMANO:
            d["l_" + c] = np.log(winsorizar(d[c].where(d[c] > 0)))

        elast = smf.ols("l_CompEjec ~ l_MCAP + l_Ingresos_usd + l_Empleados", data=c
        print(elast.summary().tables[1])
        suma = elast.params[["l_MCAP", "l_Ingresos_usd", "l_Empleados"]].sum()
        print(f"\nSuma de elasticidades = {suma:.3f}")
        print("Duplicar el tamaño de la empresa multiplica el pago ejecutivo por "
              f"{2 ** suma:.2f}, no por 2.")
```



|                | coef   | std err | z      | P> z  | [0.025 |
|----------------|--------|---------|--------|-------|--------|
| 0.975]         |        |         |        |       |        |
| Intercept      | 9.5267 | 0.427   | 22.286 | 0.000 | 8.689  |
| l_MCAP         | 0.2461 | 0.020   | 12.449 | 0.000 | 0.207  |
| l_Ingresos_usd | 0.0673 | 0.029   | 2.294  | 0.022 | 0.010  |
| l_Empleados    | 0.0315 | 0.019   | 1.671  | 0.095 | -0.005 |

Suma de elasticidades = 0.345

Duplicar el tamaño de la empresa multiplica el pago ejecutivo por 1.27, no por 2.

La suma de elasticidades es cercana a 0,34. Una empresa diez veces más grande paga a su cúpula poco más del doble, no diez veces más. Esto confirma que las razones de la sección 3 están sesgadas contra los sectores grandes, y justifica el ajuste por regresión.

## 5. La prima de sector

Se agregan efectos fijos de sector con **codificación suma**: cada coeficiente se lee como desviación frente al promedio de la muestra, no frente a un sector arbitrario de referencia. La prima reportada es  $100 \cdot (e^\beta - 1)$ : el sobrepago porcentual del sector una vez descontado su tamaño.

```
In [9]: def primas(dep, data, etiqueta):
    m = smf.ols(f"{dep} ~ l_MCAP + l_Ingresos_usd + l_Empleados + C(Sector,
        data=data).fit(cov_type='HC1')
    ef = pd.DataFrame({"coef": m.params, "p": m.pvalues}).filter(like="Sector")
    ef.index = [i.split("S.")[1].rstrip("") for i in ef.index]
    # La codificación suma omite un sector; su coeficiente es menos la suma
    omitido = [s for s in data["Sector"].dropna().unique() if s not in ef.index]
    ef.loc[omitido] = [-ef["coef"].sum(), np.nan]
    ef[etiqueta] = 100 * (np.exp(ef["coef"]) - 1)
    ef["p_" + etiqueta] = ef["p"]
    return m, ef[[etiqueta, "p_" + etiqueta]].sort_values(etiqueta, ascending=False)

m_ejec, p_ejec = primas("l_CompEjec", d, "prima_ejec_%")
print(f"Ejecutivos (AT): n = {int(m_ejec.nobs):,}, R² = {m_ejec.rsquared:.3f}")
p_ejec
```

Ejecutivos (AT): n = 1,349, R² = 0.342

Out [9]:

|                        | prima_ejec_% | p_prima_ejec_% |
|------------------------|--------------|----------------|
| Technology             | 37.67        | 0.00           |
| Consumer, Non-cyclical | 4.40         | 0.25           |
| Communications         | 2.50         | 0.82           |
| Financial              | 2.09         | 0.60           |
| Consumer, Cyclical     | 0.92         | 0.85           |
| Energy                 | -0.74        | 0.92           |
| Basic Materials        | -3.37        | 0.65           |
| Industrial             | -10.60       | 0.00           |
| Utilities              | -23.16       | NaN            |

In [10]:

```
m_ceo, p_ceo = primas("l_CompCEO", d, "prima_CEO_%")
m_junta, p_junta = primas("l_CompJunta", d, "prima_junta_%")

tabla_primas = (
    p_ejec[["prima_ejec_%"]]
    .join(p_ceo[["prima_CEO_%"]])
    .join(p_junta[["prima_junta_%"]])
    .sort_values("prima_ejec%", ascending=False)
)
print(f"CEO (AU): n = {int(m_ceo.nobs):,}, R² = {m_ceo.rsquared:.3f} | "
      f"Junta (AV): n = {int(m_junta.nobs):,}, R² = {m_junta.rsquared:.3f}")
print("\nPrima de sector sobre el pago que predice el tamaño (%):")
tabla_primas
```

CEO (AU): n = 1,314, R² = 0.196 | Junta (AV): n = 1,352, R² = 0.211

Prima de sector sobre el pago que predice el tamaño (%):

Out [10]:

|                        | prima_ejec_% | prima_CEO_% | prima_junta_% |
|------------------------|--------------|-------------|---------------|
| Technology             | 37.67        | 14.42       | 2.46          |
| Consumer, Non-cyclical | 4.40         | 6.12        | 11.78         |
| Communications         | 2.50         | -3.23       | -7.30         |
| Financial              | 2.09         | -1.63       | -1.72         |
| Consumer, Cyclical     | 0.92         | -3.26       | -5.49         |
| Energy                 | -0.74        | -0.21       | -7.55         |
| Basic Materials        | -3.37        | 5.45        | 8.21          |
| Industrial             | -10.60       | -1.82       | -3.34         |
| Utilities              | -23.16       | -13.44      | 4.87          |

In [11]:

```
# La codificación suma no reporta el p-valor del sector omitido (Utilities).
# codificación de tratamiento y base en Consumer, Non-cyclical para verifica
```

```

chequeo = smf.ols(
    "_CompEjec ~ _MCAp + _Ingresos_usd + _Empleados + C(Sector, Treatment)
    data=d,
).fit(cov_type="HC1")
ext = pd.DataFrame({"coef": chequeo.params, "p": chequeo.pvalues}).filter(lambda x: x["p"] < 0.05)
ext.index = [i.split("T.")[1].rstrip("_") for i in ext.index]
print("Contraste frente a Consumer, Non-cyclical (verificación de significancia)")
print(ext.loc[["Technology", "Industrial", "Utilities"]].round(4).to_string())

```


Contraste frente a Consumer, Non-cyclical (verificación de significancia):

|            | coef  | p    |
|------------|-------|------|
| Technology | 0.28  | 0.00 |
| Industrial | -0.16 | 0.00 |
| Utilities  | -0.31 | 0.00 |

```

In [12]: fig, ax = plt.subplots(figsize=(11, 6))
t = tabla_primas.sort_values("prima_ejec_")
y = np.arange(len(t))
h = 0.27
ax.barh(y + h, t["prima_ejec_"], h, label="Ejecutivos (AT)", color="#4C72B0")
ax.barh(y, t["prima_CEO_"], h, label="CEO (AU)", color="#DD8452")
ax.barh(y - h, t["prima_junta_"], h, label="Junta (AV)", color="#55A868")
ax.axvline(0, color="black", lw=1)
ax.set_yticks(y, t.index)
ax.set_xlabel("Prima sobre el pago predicho por el tamaño (%)")
ax.set_title("Prima de compensación por sector, ajustada por market cap, ingresos y empleados")
ax.legend(loc="lower right")
ax.grid(axis="y", alpha=0)
fig.tight_layout()
plt.show()

```



**Tecnología es el único sector con prima ejecutiva positiva y significativa: +38%**

**sobre lo que predice su tamaño.** No es un efecto de escala; es pago por encima de la curva. En el extremo opuesto están Servicios Públicos (-23%) e Industrial (-11%),

ambos significativos. Servicios Públicos es el sector regulado de la muestra y su paquete ejecutivo lo refleja.

Los otros seis sectores caen en una banda de  $\pm 5\%$  alrededor del promedio, ninguno significativo. Dicho de otro modo: **descontado el tamaño, la mitad de la dispersión entre sectores desaparece y lo que queda es un solo sector caro y dos baratos.**

Tres lecturas adicionales:

- La prima del **CEO** de Tecnología (+14%) es mucho menor que la del equipo ejecutivo completo (+38%). El sobrepago de Tecnología está repartido en el equipo, no concentrado en el CEO.
- La prima de la **junta** casi no sigue a la de los ejecutivos. Consumo No Cíclico paga a su junta un 12% por encima de lo esperado mientras su equipo ejecutivo está en el promedio. Junta y cúpula operan como dos mercados laborales separados. Servicios Públicos lo muestra en su forma más clara: -23% en ejecutivos y +5% en junta.

## 6. Qué hace la columna AW: la rotación del CEO

**Number of CEO and Equivalent Changes During FY** no mide pago, pero explica una parte del pago. Cuando hay un cambio de CEO en el año fiscal, la empresa suele reportar **dos paquetes**: la salida del saliente y la entrada del entrante. Si eso se ignora, esas empresas se ven como pagadoras generosas cuando en realidad están pagando una transición.

Se usa el **residuo** de la regresión sin sector como "prima ajustada por tamaño" a nivel empresa, y se compara entre empresas con y sin cambio de CEO.

```
In [13]: d.loc[elast.resid.index, "prima_empresa"] = elast.resid
d["hubo_cambio_CEO"] = d["CambiosCEO"] > 0

corte = d.groupby("hubo_cambio_CEO")[["prima_empresa", "CEO_sobre_ejec", "CompEjec"]
corte.index = ["Sin cambio de CEO", "Con cambio de CEO"]
corte["n"] = d.groupby("hubo_cambio_CEO")["prima_empresa"].count().values
print(corte.to_string())

brecha = corte.loc["Con cambio de CEO", "prima_empresa"] - corte.loc["Sin cambio de CEO", "prima_empresa"]
print(f"\nBrecha en la prima = {brecha:+.3f} log ≈ {100 * (np.exp(brecha) - 1):+.1f}% de pago ejecutivo adicional en el año del relevo.")
```

|                   | prima_empresa | CEO_sobre_ejec | CompEjec      | n    |
|-------------------|---------------|----------------|---------------|------|
| Sin cambio de CEO | -0.02         | 0.43           | 24,748,027.00 | 1204 |
| Con cambio de CEO | 0.24          | 0.51           | 31,649,595.00 | 145  |

Brecha en la prima = +0.260 log  $\approx$  +30% de pago ejecutivo adicional en el año del relevo.

```
In [14]: # ¿Cambia el ranking de sectores si se excluyen los años de relevo?
d_estable = d[~d["hubo_cambio_CEO"]]
_, p_estable = primas("l_CompEjec", d_estable, "prima_sin_relevo_%")
robustez = p_ejec[["prima_ejec_%"]].join(p_estable[["prima_sin_relevo_%"]])
robustez["dif_pp"] = robustez["prima_sin_relevo_%"] - robustez["prima_ejec_%"]
print(f"Muestra sin relevos: {len(d_estable):,} empresas")
robustez.sort_values("prima_ejec_%", ascending=False)
```

Muestra sin relevos: 1,347 empresas

```
Out[14]:
```

|                        | prima_ejec_% | prima_sin_relevo_% | dif_pp |
|------------------------|--------------|--------------------|--------|
| Technology             | 37.67        | 35.46              | -2.21  |
| Consumer, Non-cyclical | 4.40         | 2.83               | -1.57  |
| Communications         | 2.50         | 0.69               | -1.81  |
| Financial              | 2.09         | 3.61               | 1.51   |
| Consumer, Cyclical     | 0.92         | 2.80               | 1.88   |
| Energy                 | -0.74        | -0.00              | 0.74   |
| Basic Materials        | -3.37        | -2.59              | 0.78   |
| Industrial             | -10.60       | -11.35             | -0.75  |
| Utilities              | -23.16       | -22.47             | 0.70   |

Un relevo de CEO agrega en torno a un 30% al pago ejecutivo reportado del año, y sube la participación del CEO en el paquete del 43% al 51%. Pero excluir esos casos **no reordena el ranking de sectores**: la prima de Tecnología y el descuento de Servicios Públicos sobreviven. La conclusión de la sección 5 no depende de los años de transición.

## 7. Concentración: cuánto del paquete se lleva el CEO

Con AT y AU se construye `CompCEO / CompEjec`. Es una medida de concentración del poder de negociación dentro de la cúpula, y no depende del tamaño de la empresa.

```
In [15]: conc = d.groupby("Sector")["CEO_sobre_ejec"].agg(["median", "count"]).sort_v
conc.columns = ["CEO/Ejecutivos (mediana)", "n"]
print("Participación del CEO en el paquete ejecutivo total:")
print(conc.to_string())

sub = d[["CEO_sobre_ejec", "l_MCAP"]].dropna()
print(f"\nSpearman(CEO/Ejec, log MCAP) = {sub['CEO_sobre_ejec'].corr(sub['l_
" → la concentración no es un fenómeno de tamaño.")
```

| Participación del CEO en el paquete ejecutivo total: |                          |     |
|------------------------------------------------------|--------------------------|-----|
|                                                      | CEO/Ejecutivos (mediana) | n   |
| Sector                                               |                          |     |
| Industrial                                           | 0.47                     | 205 |
| Basic Materials                                      | 0.46                     | 47  |
| Utilities                                            | 0.45                     | 52  |
| Consumer, Cyclical                                   | 0.44                     | 180 |
| Consumer, Non-cyclical                               | 0.43                     | 271 |
| Technology                                           | 0.42                     | 169 |
| Energy                                               | 0.42                     | 69  |
| Financial                                            | 0.42                     | 293 |
| Communications                                       | 0.42                     | 76  |

Spearman(CEO/Ejec, log MCAP) = -0.082 → la concentración no es un fenómeno de tamaño.

La mediana se mueve en una banda estrecha, del 42% al 47%. Industrial y Materiales Básicos concentran algo más en el CEO; Tecnología y Comunicaciones, algo menos. Es coherente con el hallazgo de la sección 5: Tecnología paga más, pero lo reparte.

## 8. Ranking de empresas por prima ajustada por tamaño

```
In [16]: cols = ["Ticker", "Sector", "CompEjec", "MCAP", "Ingresos", "Empleados", "pr
top = d.dropna(subset=["prima_empresa"]).sort_values("prima_empresa", ascend
top["prima_%"] = 100 * (np.exp(top["prima_empresa"]) - 1)

print("15 empresas que más pagan frente a lo que predice su tamaño:")
display(top.head(15)[cols[:-1] + ["prima_%"]].reset_index(drop=True))
print("\n15 empresas que menos pagan frente a lo que predice su tamaño:")
display(top.tail(15)[cols[:-1] + ["prima_%"]].iloc[::-1].reset_index(drop=Tr
```

15 empresas que más pagan frente a lo que predice su tamaño:

|           | <b>Ticker</b>         | <b>Sector</b>              | <b>CompEjec</b>  | <b>MCAP</b>       | <b>Ingresos</b> | <b>Empleados</b> | <b>P</b> |
|-----------|-----------------------|----------------------------|------------------|-------------------|-----------------|------------------|----------|
| <b>0</b>  | NBIS<br>US<br>Equity  | Technology                 | 1,607,000,000.00 | 6,171,260,295.78  | 117.50          | 26,361.00        |          |
| <b>1</b>  | COHR<br>US<br>Equity  | Industrial                 | 142,585,324.00   | 9,733,497,557.63  | 4,707.69        | 26,157.00        |          |
| <b>2</b>  | LYFT<br>US<br>Equity  | Communications             | 112,454,676.00   | 4,798,738,222.88  | 5,786.02        | 2,934.00         |          |
| <b>3</b>  | CG US<br>Equity       | Financial                  | 230,074,896.00   | 14,458,951,406.49 | 5,449.80        | 2,200.00         |          |
| <b>4</b>  | EDR<br>US<br>Equity   | Communications             | 156,160,668.00   | 13,454,096,884.80 | 7,110.98        | 10,000.00        |          |
| <b>5</b>  | BILI<br>US<br>Equity  | Communications             | 408,916,000.00   | 9,187,711,504.77  | 26,831.53       | 12,281.00        |          |
| <b>6</b>  | MARA<br>US<br>Equity  | Financial                  | 82,894,427.00    | 4,637,403,650.07  | 656.38          | 152.00           |          |
| <b>7</b>  | AU US<br>Equity       | Basic Materials            | 377,684,000.00   | 15,423,570,614.88 | 5,793.00        | 33,658.00        |          |
| <b>8</b>  | LAZ<br>US<br>Equity   | Financial                  | 90,150,092.00    | 5,057,559,181.35  | 3,139.90        | 3,263.00         |          |
| <b>9</b>  | LBTYA<br>US<br>Equity | Communications             | 87,941,633.00    | 4,082,419,554.43  | 4,341.90        | 6,820.00         |          |
| <b>10</b> | DOCU<br>US<br>Equity  | Technology                 | 115,063,888.00   | 15,729,521,758.26 | 2,761.88        | 6,840.00         |          |
| <b>11</b> | RPRX<br>US<br>Equity  | Consumer, Non-<br>cyclical | 103,077,077.00   | 18,878,841,219.25 | 2,263.58        | 99.00            |          |
| <b>12</b> | MDGL<br>US<br>Equity  | Consumer, Non-<br>cyclical | 69,793,033.00    | 7,267,933,773.36  | 180.13          | 528.00           |          |
| <b>13</b> | VNO<br>US<br>Equity   | Financial                  | 82,537,493.00    | 7,278,888,561.20  | 1,787.69        | 2,568.00         |          |
| <b>14</b> | INFA<br>US<br>Equity  | Technology                 | 77,515,421.00    | 5,413,496,932.94  | 1,640.02        | 5,200.00         |          |


15 empresas que menos pagan frente a lo que predice su tamaño:

|           | <b>Ticker</b>        | <b>Sector</b>              | <b>CompEjec</b> | <b>MCAP</b>          | <b>Ingresos</b> | <b>Empleados</b> |
|-----------|----------------------|----------------------------|-----------------|----------------------|-----------------|------------------|
| <b>0</b>  | PDD<br>US<br>Equity  | Communications             | 100,000.00      | 160,583,546,212.45   | 247,639.20      | 17,403.00        |
| <b>1</b>  | TCOM<br>US<br>Equity | Communications             | 1,600,000.00    | 40,075,220,691.00    | 53,294.00       | 36,249.00        |
| <b>2</b>  | AMZN<br>US<br>Equity | Communications             | 4,600,271.00    | 2,061,682,268,138.08 | 637,959.00      | 1,556,000.00     |
| <b>3</b>  | SCCO<br>US<br>Equity | Basic Materials            | 2,606,537.00    | 70,430,339,776.30    | 11,433.40       | 15,810.00        |
| <b>4</b>  | XPEV<br>US<br>Equity | Consumer,<br>Cyclical      | 1,595,000.00    | 21,807,692,357.18    | 30,676.07       | 13,550.00        |
| <b>5</b>  | VIPS<br>US<br>Equity | Communications             | 1,200,000.00    | 8,475,137,771.14     | 108,420.83      | 14,638.00        |
| <b>6</b>  | JD US<br>Equity      | Communications             | 4,100,000.00    | 65,844,249,799.68    | 1,158,819.00    | 517,124.00       |
| <b>7</b>  | UI US<br>Equity      | Communications             | 1,583,705.00    | 18,203,357,113.41    | 1,928.49        | 1,515.00         |
| <b>8</b>  | BIDU<br>US<br>Equity | Communications             | 4,000,000.00    | 32,466,912,104.71    | 133,125.00      | 39,800.00        |
| <b>9</b>  | TAL<br>US<br>Equity  | Consumer, Non-<br>cyclical | 1,900,000.00    | 7,800,509,570.25     | 1,490.44        | 15,000.00        |
| <b>10</b> | FTAI<br>US<br>Equity | Financial                  | 1,460,310.00    | 10,018,204,747.75    | 1,734.90        | 580.00           |
| <b>11</b> | MMYT<br>US<br>Equity | Communications             | 2,000,000.00    | 9,326,022,185.70     | 782.52          | 4,576.00         |
| <b>12</b> | HESM<br>US<br>Equity | Energy                     | 548,025.00      | 10,502,980,489.60    | 1,495.50        | 220.00           |
| <b>13</b> | NTES<br>US<br>Equity | Technology                 | 5,500,000.00    | 66,043,091,251.20    | 105,295.24      | 29,128.00        |
| <b>14</b> | VNET<br>US<br>Equity | Communications             | 2,000,000.00    | 3,051,423,473.59     | 7,412.93        | 3,038.00         |



```
In [17]: fig, ax = plt.subplots(figsize=(11, 6.5))
paleta = plt.cm.tab10(np.linspace(0, 1, d["Sector"].unique()))
for (s, g), c in zip(d.groupby("Sector"), paleta):
    ax.scatter(g["l_MCAP"], g["l_CompEjec"], s=14, alpha=0.55, label=s, color=c)

x = np.linspace(d["l_MCAP"].min(), d["l_MCAP"].max(), 50)
ajuste = smf.ols("l_CompEjec ~ l_MCAP", data=d).fit()
ax.plot(x, ajuste.params.iloc[0] + ajuste.params.iloc[1] * x, "k--", lw=2,
        label=f"ajuste (pendiente {ajuste.params.iloc[1]:.2f})")
ax.set_xlabel("log(market cap)")
ax.set_ylabel("log(compensación ejecutiva)")
ax.set_title("El pago crece con el tamaño, pero con pendiente muy inferior a 1")
ax.legend(fontsize=8, ncol=2, loc="upper left")
fig.tight_layout()
plt.show()
```



## 9. Exportación de resultados

```
In [18]: salida = "resultados_compensacion.xlsx"
with pd.ExcelWriter(salida, engine="openpyxl") as w:
    nivel.to_excel(w, sheet_name="nivel_absoluto")
    razones.to_excel(w, sheet_name="razones_por_tamano")
    rank.to_excel(w, sheet_name="ranking_por_denominador")
    tabla_primas.to_excel(w, sheet_name="primas_de_sector")
    robustez.to_excel(w, sheet_name="robustez_sin_relevos")
    conc.to_excel(w, sheet_name="concentracion_CEO")
    top[cols[:-1] + ["prima_%"]].head(50).to_excel(w, sheet_name="top50_sobr")
    top[cols[:-1] + ["prima_%"]].tail(50).to_excel(w, sheet_name="top50_subp")
print(f"Guardado: {salida}")
```

Guardado: resultados\_compensacion.xlsx

# Conclusiones

1. **En nivel absoluto ganan Comunicaciones y Tecnología, pero eso es tamaño.** A nivel de empresa la compensación correlaciona con capitalización, ingresos y empleados con rho entre +0,4 y +0,5. Sin normalizar, la tabla no dice nada sobre generosidad.
2. **El ranking normalizado depende del denominador.** Por ingresos gana Tecnología; por empleado gana Energía; por puntos básicos de *market cap* gana Materiales Básicos. Comunicaciones pasa del primer puesto al séptimo. Reportar una sola razón es elegir una conclusión.
3. **La elasticidad del pago al tamaño es ~0,34.** Las razones simples castigan a las empresas grandes por construcción. Este es el argumento para usar la regresión y no el cociente.
4. **Ajustado por tamaño, solo tres sectores se separan del promedio:** Tecnología paga un 38% de más; Servicios Públicos un 23% de menos e Industrial un 11% de menos. Los otros seis quedan en una banda de  $\pm 5\%$  sin significancia estadística.
5. **El sobrepago de Tecnología está en el equipo, no en el CEO.** La prima del equipo ejecutivo (+38%) casi triplica la del CEO (+14%), y su razón CEO/Ejecutivos (42%) está entre las más bajas de la muestra.
6. **La junta se paga en un mercado aparte.** Su prima por sector no sigue a la de los ejecutivos: Consumo No Cíclico paga a su junta un 12% de más con un equipo ejecutivo en el promedio.
7. **Un relevo de CEO agrega ~30% al pago reportado del año, pero no cambia el ranking.** Excluir los 145 casos de relevo mueve las primas de sector menos de 2 puntos porcentuales.

**Límites.** Corte transversal de un solo año: mide asociación, no causalidad. No hay retorno de la acción, así que no se puede evaluar si la prima de Tecnología está justificada por desempeño. Las tres columnas de pago son totales reportados, sin descomposición entre efectivo, acciones y opciones, y esa mezcla difiere sistemáticamente entre sectores.