

¿Las empresas con mejor gobierno corporativo tienen mejor desempeño?
Pregunta de investigación aplicada al archivo 07. T1_GC_datos.xlsx (1.878 empresas, año fiscal 2023). **Qué se puede responder con estos datos y qué no** Los datos son un **corte transversal de un solo año**. Eso permite medir *asociación*, no *causalidad*. No hay retornos de la acción ni serie temporal, así que "desempeño" se mide con:

Dimensión	Variables
Rentabilidad contable	ROE, ROA, margen operativo
Creación de valor	ROIC/WACC
Costo de capital	WACC
Valoración de mercado	Price/Book, P/E

Y "gobierno corporativo" con dos niveles:

- Puntaje compuesto:** **BESG Governance Pillar Score** (cobertura: 1.433 empresas).
- Estructura de la junta:** independencia, tamaño, diversidad, edad promedio, dualidad del CEO, junta escalonada (*classified board*). Cobertura mucho menor, entre 360 y 440 empresas.
- Estrategia:** correlaciones simples → quintiles de gobierno → regresiones con controles de tamaño, apalancamiento y efectos fijos de sector → modelo multivariado de estructura de junta.

1. Preparación de datos

In [190]...

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import statsmodels.formula.api as smf
from scipy import stats

pd.set_option("display.max_columns", 60)
pd.set_option("display.width", 200)
pd.set_option("display.float_format", lambda x: f"{x:,.3f}")
plt.rcParams["figure.figsize"] = (11, 6)
plt.rcParams["axes.grid"] = True
plt.rcParams["grid.alpha"] = 0.3

df = pd.read_excel("07. T1_GC_datos.xlsx", sheet_name="datos")
df = df.drop(
    columns=[c for c in df.columns if c.endswith(".1")]
) # columnas duplicadas del archivo

RENOMBRES = {
    "BESG Governance Pillar Score": "G",
    "BESG ESG Score": "ESG",
    "Governance Disclosure Score": "DivulgGob",
    "BESG BOD Diversity Issue Score": "GDiversidad",
    "Return on Common Equity": "ROE",
    "Return on Assets": "ROA",
    "ROIC/WACC Ratio": "ROIC_WACC",
    "Weighted Average Cost of Cap": "WACC",
    "Operating Margin": "MargenOp",
    "Gross Margin": "MargenBruto",
    "Price to Book Ratio": "PB",
    "Price Earnings Ratio (P/E)": "PE",
    "Dividend 12 Month Yld - Gross": "DivYield",
    "Current Market Cap": "MCAP",
    "Revenue": "Ingresos",
    "Industry Sector": "Sector",
    "Total Debt to Total Assets": "DeudaActivos",
    "Total Debt to Total Equity": "DeudaPatrimonio",
    "Board Size": "TamJunta",
    "Board Average Age": "EdadJunta",
    "Number of Independent Directors": "NIndep",
    "Independent Directors Board Meeting Attendance %": "Asistencia",
    "% Women on Board": "PctMujeresJunta",
    "Board Diversity Percentage": "DiversidadJunta",
    "CEO Duality": "Dualidad",
    "Classified Board System": "JuntaEscalonada",
    "Poison Pill Plan": "PoisonPill",
    "Chg of Ctrl Benefits/Golden Parachute Agreements": "ParacaidasDorado",
    "Number of CEO and Equivalent Changes During FY": "CambiosCEO",
    "Total Compensation Paid to CEO and Equivalent": "CompCEO",
}

df = df.rename(columns=RENOMBRES)
df["Simbolo"] = df["Ticker"].str.replace(r"\s+US Equity$", "", regex=True)

# Variables derivadas
df["logMC"] = np.log(df["MCAP"].where(df["MCAP"] > 0)) # control de tamaño
```

```

df["PctIndep"] = df["NIndep"] / df["TamJunta"] * 100 # % de directores inde
df["dual"] = df["Dualidad"].map({"Y": 1, "N": 0}) # CEO es también presiden
df["escalonada"] = df["JuntaEscalonada"].map({"Y": 1, "N": 0})

DESEMPENO = ["ROA", "ROE", "ROIC_WACC", "MargenOp", "WACC", "PB", "PE"]
GOBIERNO = [
    "G",
    "PctIndep",
    "TamJunta",
    "PctMujeresJunta",
    "DiversidadJunta",
    "EdadJunta",
    "Asistencia",
    "dual",
    "escalonada",
]

print(f"Empresas: {len(df):,}")
df[["G"] + DESEMPENO].notna().sum().to_frame("observaciones_con_dato")

```

Empresas: 1,878

	observaciones_con_dato
G	1433
ROA	1471
ROE	1385
ROIC_WACC	1492
MargenOp	1475
WACC	1492
PB	1409
PE	1281

1.1 Cobertura de las variables de gobiernoEl punto crítico del ejercicio: el puntaje compuesto cubre el 76% de la muestra, pero las variables de estructura de junta apenas superan el 20%.

```

In [191... cobertura = (
    df[GOBIERNO]
    .notna()
    .sum()
    .to_frame("con_dato")
    .assign(pct=lambda d: (100 * d["con_dato"] / len(df)).round(1))
    .sort_values("con_dato", ascending=False)
)
cobertura

```

Out [191...

	con_dato	pct
G	1433	76.300
dual	442	23.500
TamJunta	438	23.300
PctMujeresJunta	437	23.300
EdadJunta	432	23.000
escalonada	428	22.800
Asistencia	390	20.800
PctIndep	381	20.300
DiversidadJunta	239	12.700

In [192...

```
# ¿Quiénes son las empresas con datos de estructura de junta? Si son sistemá
# distintas al resto, los resultados de esa submuestra no se generalizan.
df["tiene_estructura"] = df["TamJunta"].notna()
comparacion_muestra = df.groupby("tiene_estructura")[
    ["logMC", "Ingresos", "G", "ROA", "ESG"]
].median()
comparacion_muestra.index = ["Sin datos de junta", "Con datos de junta"]
print(comparacion_muestra.round(2))

mc_con = df.loc[df["tiene_estructura"], "MCAP"].median()
mc_sin = df.loc[~df["tiene_estructura"], "MCAP"].median()
print(f"\nMediana de market cap: con datos = {mc_con:,.0f} | sin datos = {mc_sin:,.0f}")
print(f"Razón = {mc_con / mc_sin:.1f}x")
```

	logMC	Ingresos	G	ROA	ESG
Sin datos de junta	22.780	4,179.190	7.210	3.940	4.050
Con datos de junta	22.950	4,810.790	6.860	5.330	3.710

Mediana de market cap: con datos = 9,233,207,602 | sin datos = 7,795,143,311
 Razón = 1.2x

Sesgo de selección confirmado. Las empresas con datos de estructura de junta son muchomás grandes. Los resultados de esa submuestra describen a las grandes capitalizaciones, no al universo completo. Se reporta el **n** en cada tabla por esa razón.

2. Tratamiento de valores extremos

Las variables financieras tienen colas muy pesadas: hay márgenes operativos de miles por ciento negativos y ROE de tres dígitos. Sin *winsorización* una sola empresa mueve cualquier promedio. Se recortan los percentiles 1 y 99.

In [193...

```
def winsorizar(s, p=0.01):
    """Recorta la serie a los percentiles [p, 1-p] sin eliminar observaciones"""
```

```

    lo, hi = s.quantile([p, 1 - p])
    return s.clip(lo, hi)

# Ejemplo del efecto sobre el margen operativo
antes = df["MargenOp"]
despues = winsorizar(df["MargenOp"])
print(
    pd.DataFrame(
        {"sin winsorizar": antes.describe(), "winsorizada": despues.describe()
        }).round(2)
)

# Se crea una copia con las variables de desempeño winsorizadas
dfw = df.copy()
for c in DESEMPENO:
    dfw[c] = winsorizar(dfw[c])

```

	sin winsorizar	winsorizada
count	1,475.000	1,475.000
mean	-321.120	8.210
std	11,458.930	51.000
min	-438,789.710	-375.250
25%	5.660	5.660
50%	14.220	14.220
75%	24.110	24.110
max	3,399.190	70.830

3. Correlaciones simples

```

In [194...
filas = []
for g in ["G", "PctIndep", "TamJunta", "PctMujeresJunta", "EdadJunta", "Asis
    for y in DESEMPENO:
        sub = dfw[[g, y]].dropna()
        if len(sub) < 80:
            continue
        filas.append(
            {
                "gobierno": g,
                "desempeno": y,
                "n": len(sub),
                "pearson": sub[g].corr(sub[y]),
                "spearman": sub[g].corr(sub[y], method="spearman"),
            }
        )

corr = pd.DataFrame(filas)
matriz_spearman = corr.pivot(index="gobierno", columns="desempeno", values="
    DESEMPENO
]
print("Correlación de Spearman entre variables de gobierno y de desempeño:")
matriz_spearman

```


Correlación de Spearman entre variables de gobierno y de desempeño:

Out [194...

	desempeno	ROA	ROE	ROIC_WACC	MargenOp	WACC	PB	PE
gobierno								
Asistencia	0.018	-0.003		0.040	0.025	0.049	-0.052	-0.020
EdadJunta	0.142	0.187		0.174	0.143	-0.261	-0.108	-0.121
G	0.120	0.149		0.208	0.169	-0.320	-0.144	-0.142
PctIndep	0.097	0.129		0.238	0.062	-0.280	-0.007	-0.106
PctMujeresJunta	0.100	0.151		0.166	0.007	-0.275	0.049	-0.091
TamJunta	0.104	0.236		0.211	0.122	-0.314	-0.025	-0.189

In [195...

```
fig, ax = plt.subplots(figsize=(10, 5))
im = ax.imshow(matriz_spearman, cmap="RdBu_r", vmin=-0.4, vmax=0.4)
ax.set_xticks(
    range(matriz_spearman.shape[1]), matriz_spearman.columns, rotation=30, h
)
ax.set_yticks(range(matriz_spearman.shape[0]), matriz_spearman.index)
for i in range(matriz_spearman.shape[0]):
    for j in range(matriz_spearman.shape[1]):
        v = matriz_spearman.iloc[i, j]
        if pd.notna(v):
            ax.text(
                j,
                i,
                f"{v:.2f}",
                ha="center",
                va="center",
                fontsize=9,
                color="white" if abs(v) > 0.25 else "black",
            )
ax.set_title("Gobierno corporativo vs. desempeño (Spearman)")
ax.grid(False)
fig.colorbar(im, ax=ax, shrink=0.8, label="rho")
fig.tight_layout()
plt.show()
```



Primera lectura: el signo es el esperado en rentabilidad (positivo) y, sobre todo, en **el costo de capital** (negativo y de mayor magnitud). Los múltiplos de valoración (P/B, P/E) van en dirección contraria, lo que es consistente con que las empresas mejor gobernadas sean más maduras y coticen a múltiplos más bajos. Pero la correlación simple no descarta el sospechoso obvio: **el tamaño**.

```
In [196... # El tamaño se correlaciona tanto con gobierno como con desempeño: es un cor
print("Correlación de Spearman con el tamaño (log market cap):")
for v in ["G", "PctIndep", "TamJunta", "ROA", "ROE", "WACC"]:
    sub = dfw[[v, "logMC"]].dropna()
    print(
        f" {v:16s} rho = {sub[v].corr(sub['logMC'], method='spearman'):+.3f
    )
```

Correlación de Spearman con el tamaño (log market cap):

G	rho = +0.178	(n = 1,433)
PctIndep	rho = +0.144	(n = 381)
TamJunta	rho = +0.271	(n = 438)
ROA	rho = +0.270	(n = 1,471)
ROE	rho = +0.299	(n = 1,385)
WACC	rho = -0.081	(n = 1,492)

4. Quintiles de gobierno corporativo

```
In [197... g_ok = dfw[dfw["G"].notna()].copy()
g_ok["Quintil"] = pd.qcut(
    g_ok["G"], 5, labels=["Q1 (peor)", "Q2", "Q3", "Q4", "Q5 (mejor)"]
)
```

```

tabla_q = g_ok.groupby("Quintil", observed=True).agg(
    n=("G", "size"),
    G_medio=("G", "mean"),
    ROA=("ROA", "mean"),
    ROE=("ROE", "mean"),
    MargenOp=("MargenOp", "mean"),
    ROIC_WACC=("ROIC_WACC", "mean"),
    WACC=("WACC", "mean"),
    PB=("PB", "mean"),
    logMC=("logMC", "mean"),
)
tabla_q

```

Out [197...

	n	G_medio	ROA	ROE	MargenOp	ROIC_WACC	WACC	PB	logMC
Quintil									
Q1 (peor)	287	5.118	1.038	5.768	-2.834	0.204	9.777	9.058	23.028
Q2	286	6.531	2.740	10.881	3.647	0.737	8.644	6.287	22.958
Q3	287	7.136	5.986	19.777	15.801	1.062	8.287	6.575	23.140
Q4	286	7.628	5.896	17.907	15.985	1.136	8.083	4.975	23.408
Q5 (mejor)	287	8.190	5.841	20.370	19.287	1.296	7.529	5.328	23.638

In [198...

```

# Prueba formal de la diferencia entre el mejor y el peor quintil
print("Diferencia Q5 (mejor gobierno) menos Q1 (peor gobierno), prueba t de resultados_q = []
for y in ["ROA", "ROE", "MargenOp", "ROIC_WACC", "WACC", "PB"]:
    a = g_ok.loc[g_ok["Quintil"] == "Q5 (mejor)", y].dropna()
    b = g_ok.loc[g_ok["Quintil"] == "Q1 (peor)", y].dropna()
    t, p = stats.ttest_ind(a, b, equal_var=False)
    resultados_q.append(
        {
            "variable": y,
            "Q5": a.mean(),
            "Q1": b.mean(),
            "diferencia": a.mean() - b.mean(),
            "t": t,
            "p_valor": p,
            "n_Q5": len(a),
            "n_Q1": len(b),
        }
    )
pd.DataFrame(resultados_q).set_index("variable")

```

Diferencia Q5 (mejor gobierno) menos Q1 (peor gobierno), prueba t de Welch:


Out [198...

	Q5	Q1	diferencia	t	p_valor	n_Q5	n_Q1
variable							
ROA	5.841	1.038	4.803	5.192	0.000	287	287
ROE	20.370	5.768	14.602	5.955	0.000	273	272
MargenOp	19.287	-2.834	22.121	4.997	0.000	287	281
ROIC_WACC	1.296	0.204	1.093	7.284	0.000	287	287
WACC	7.529	9.777	-2.248	-12.612	0.000	287	287
PB	5.328	9.058	-3.730	-3.219	0.001	273	274

In [199...

```
fig, axes = plt.subplots(2, 2, figsize=(13, 8))
metricas = [
    ("ROA", "ROA (%)" ),
    ("ROE", "ROE (%)" ),
    ("WACC", "WACC (%)" ),
    ("ROIC_WACC", "ROIC / WACC"),
]
for ax, (col, etiqueta) in zip(axes.ravel(), metricas):
    medias = g_ok.groupby("Quintil", observed=True)[col].mean()
    colores = ["#C44E52" if col == "WACC" else "#4C72B0"] * len(medias)
    ax.bar(range(len(medias)), medias.values, color=colores)
    ax.set_xticks(range(len(medias)), medias.index, rotation=20, ha="right",
    ax.set_title(f"{etiqueta} por quintil de gobierno")
    ax.set_ylabel(etiqueta)
    for i, v in enumerate(medias.values):
        ax.text(
            i, v, f"{v:.2f}", ha="center", va="bottom" if v >= 0 else "top",
        )

fig.suptitle("Desempeño promedio por quintil del puntaje de gobierno BESG",
fig.tight_layout()
plt.show()
```



El patrón es monótono en el costo de capital: cada quintil de gobierno tiene un WACC menor que el anterior, sin excepciones. En rentabilidad el salto grande está entre Q1-Q2 y Q3, y luego se aplana: parece un efecto de umbral más que lineal. Falta lo importante: ¿sobrevive al control por tamaño y sector?

5. Regresiones con controles Especificación:

$$y_i = \alpha + \beta \cdot \text{Gobierno}_i + \gamma_1 \log(\text{MCAP}_i) + \gamma_2 \text{Dev}$$

Los efectos fijos de sector absorben las diferencias estructurales entre industrias. Los errores estándar son robustos a heterocedasticidad (HC1).

```
In [200... def modelo(y, x, datos, controles=("logMC", "DeudaActivos"), fe_sector=True)
    """Estima la regresión y devuelve un dict con el coeficiente de interés.
    cols = [y, x, *controles, "Sector"]
    d = datos[cols].dropna()
    if len(d) < 60:
        return None
    formula = f"{y} ~ {x}" + "".join(f" + {c}" for c in controles)
    if fe_sector:
        formula += " + C(Sector)"
    m = smf.ols(formula, data=d).fit(cov_type="HC1")
    return {
        "y": y,
        "x": x,
        "n": len(d),
```

```

        "coef": m.params[x],
        "ee": m.bse[x],
        "t": m.tvalues[x],
        "p_valor": m.pvalues[x],
        "R2": m.rsquared,
    }

filas = []
for y in ["ROA", "ROE", "MargenOp", "ROIC_WACC", "WACC"]:
    simple = modelo(y, "G", dfw, controles=(), fe_sector=False)
    completo = modelo(y, "G", dfw)
    filas.append(
        {
            "desempeno": y,
            "n": completo["n"],
            "b_sin_controles": simple["coef"],
            "p_sin": simple["p_valor"],
            "b_con_controles": completo["coef"],
            "p_con": completo["p_valor"],
            "R2_con": completo["R2"],
        }
    )

print("Efecto del puntaje de gobierno (G) sobre el desempeño, por punto de p
pd.DataFrame(filas).set_index("desempeno")

```

Efecto del puntaje de gobierno (G) sobre el desempeño, por punto de puntaje:

Out[200...

	n	b_sin_controles	p_sin	b_con_controles	p_con	R2_con
desempeno						
ROA	1431	1.198	0.000	0.882	0.000	0.121
ROE	1354	3.969	0.000	2.640	0.000	0.132
MargenOp	1417	5.201	0.000	3.808	0.000	0.106
ROIC_WACC	1432	0.267	0.000	0.207	0.000	0.112
WACC	1432	-0.658	0.000	-0.550	0.000	0.322

Este es el resultado central. El coeficiente del puntaje de gobierno se reduce al agregar controles (parte de la correlación bruta era tamaño y sector), pero **sigue siendo significativo en las cinco medidas de desempeño**. Un punto más de puntaje de gobierno se asocia con: - unos 0,9 puntos porcentuales más de ROA, - unos 2,6 puntos porcentuales más de ROE, - unos 3,2 puntos porcentuales más de margen operativo, - un ROIC/WACC 0,20 mayor, - y un WACC unos 0,55 puntos porcentuales **menor**.

5.1 Estructura de la junta, variable por variable Aquí el puntaje compuesto se reemplaza por las características concretas de la junta. Advertencia: la muestra cae a unas 360-440 empresas grandes.

In [201...

```
filas = []
for x in [
    "PctIndep",
    "TamJunta",
    "PctMujeresJunta",
    "DiversidadJunta",
    "EdadJunta",
    "Asistencia",
]:
    for y in ["ROA", "ROE", "MargenOp", "ROIC_WACC", "WACC"]:
        r = modelo(y, x, dfw)
        if r:
            filas.append(r)

estructura = pd.DataFrame(filas)
estructura["signif"] = np.where(
    estructura["p_valor"] < 0.01,
    "***",
    np.where(
        estructura["p_valor"] < 0.05,
        "**",
        np.where(estructura["p_valor"] < 0.10, "*", ""),
    ),
)
)
tabla_estructura = estructura.pivot(index="x", columns="y", values="coef")
tabla_p = estructura.pivot(index="x", columns="y", values="p_valor")

print("Coeficientes (controlando tamaño, deuda y sector):")
print(tabla_estructura.round(4).to_string())
print("\nnp-valores:")
print(tabla_p.round(3).to_string())
print("\nTamaño de muestra por variable:")
print(estructura.groupby("x")["n"].max().to_string())
```

Coeficientes (controlando tamaño, deuda y sector):						
y	MargenOp	ROA	ROE	ROIC_WACC	WACC	
x						
Asistencia	-0.151	-0.024	-0.271	0.004	0.012	
DiversidadJunta	0.176	0.039	0.064	0.020	-0.015	
EdadJunta	0.951	0.380	0.794	0.057	-0.112	
PctIndep	0.336	0.037	-0.012	0.016	-0.048	
PctMujeresJunta	0.596	0.077	0.144	0.014	-0.051	
TamJunta	3.029	0.116	0.741	0.074	-0.259	

p-valores:						
y	MargenOp	ROA	ROE	ROIC_WACC	WACC	
x						
Asistencia	0.553	0.685	0.051	0.633	0.328	
DiversidadJunta	0.623	0.562	0.656	0.097	0.247	
EdadJunta	0.070	0.002	0.005	0.006	0.000	
PctIndep	0.209	0.427	0.916	0.038	0.000	
PctMujeresJunta	0.060	0.186	0.267	0.111	0.000	
TamJunta	0.043	0.721	0.358	0.160	0.000	


Tamaño de muestra por variable:

x	
Asistencia	389
DiversidadJunta	238
EdadJunta	431
PctIndep	380
PctMujeresJunta	436
TamJunta	437

```
In [202... # Vista compacta: qué es significativo y en qué dirección
mapa = tabla_estructura.copy()
mapa_signif = tabla_p < 0.05

fig, ax = plt.subplots(figsize=(9, 4.5))
normalizado = mapa.div(
    mapa.abs().max(axis=0), axis=1
) # escala por columna, solo para el color
im = ax.imshow(normalizado, cmap="RdBu_r", vmin=-1, vmax=1)
ax.set_xticks(range(mapa.shape[1]), mapa.columns, rotation=20, ha="right")
ax.set_yticks(range(mapa.shape[0]), mapa.index)
for i in range(mapa.shape[0]):
    for j in range(mapa.shape[1]):
        v = mapa.iloc[i, j]
        marca = "*" if mapa_signif.iloc[i, j] else ""
        ax.text(j, i, f"{v:+.3f}{marca}", ha="center", va="center", fontsize=10)
ax.set_title(
    "Estructura de junta vs. desempeño\n(coeficiente con controles; * = p < 0.05)
)
ax.grid(False)
fig.tight_layout()
plt.show()
```

Estructura de junta vs. desempeño (coeficiente con controles; * = $p < 0.05$)



Hallazgo clave y contraintuitivo: las características individuales de la junta (independencia, tamaño, diversidad de género) **no explican la rentabilidad contable** una vez que se controla por tamaño y sector. Todos los coeficientes sobre ROA y ROE quedan sin significancia estadística. Pero **sí explican el costo de capital**: más independientes, junta más grande y mayor participación de mujeres se asocian consistentemente con un WACC menor. El mercado parece descontar la calidad del gobierno en el precio del capital, no en la rentabilidad operativa.

5.2 Mecanismos de blindaje: dualidad del CEO y junta escalonada

```
In [203... binarias = {
    "dual": "CEO es también presidente de la junta",
    "escalonada": "Junta escalonada (classified board)",
    "PoisonPill": "Poison pill",
    "ParacaidasDorado": "Paracaídas dorado",
}

filas = []
for var, etiqueta in binarias.items():
    serie = dfw[var]
    if serie.dtype == object:
        serie = serie.map({"Y": 1, "N": 0})
    for y in ["ROA", "ROE", "WACC", "G"]:
        d = pd.DataFrame({"flag": serie, "y": dfw[y]}).dropna()
        con = d.loc[d["flag"] == 1, "y"]
```

```

sin = d.loc[d["flag"] == 0, "y"]
if len(con) < 30 or len(sin) < 30:
    filas.append(
        {
            "mecanismo": etiqueta,
            "desempeno": y,
            "n_con": len(con),
            "n_sin": len(sin),
            "media_con": np.nan,
            "media_sin": np.nan,
            "diferencia": np.nan,
            "p_valor": np.nan,
        }
    )
    continue
t, p = stats.ttest_ind(con, sin, equal_var=False)
filas.append(
    {
        "mecanismo": etiqueta,
        "desempeno": y,
        "n_con": len(con),
        "n_sin": len(sin),
        "media_con": con.mean(),
        "media_sin": sin.mean(),
        "diferencia": con.mean() - sin.mean(),
        "p_valor": p,
    }
)

pd.DataFrame(filas).set_index(["mecanismo", "desempeno"])

```

Out [203... n_con n_sin media_con media_sin diferencia p_valor

mecanismo	desempeno						
CEO es también presidente de la junta	ROA	154	286	3.684	5.141	-1.458	0.220
	ROE	144	265	12.950	17.284	-4.334	0.175
	WACC	154	288	9.336	8.790	0.546	0.032
	G	152	277	6.295	6.672	-0.378	0.015
Junta escalonada (classified board)	ROA	142	284	2.739	5.865	-3.127	0.025
	ROE	131	266	9.808	19.420	-9.612	0.002
	WACC	142	286	9.627	8.647	0.980	0.000
	G	135	279	5.924	6.889	-0.965	0.000
Poison pill	ROA	0	0	NaN	NaN	NaN	NaN
	ROE	0	0	NaN	NaN	NaN	NaN
	WACC	0	0	NaN	NaN	NaN	NaN
	G	0	0	NaN	NaN	NaN	NaN
Paracaídas dorado	ROA	0	0	NaN	NaN	NaN	NaN
	ROE	0	0	NaN	NaN	NaN	NaN
	WACC	0	0	NaN	NaN	NaN	NaN
	G	0	0	NaN	NaN	NaN	NaN

La *poison pill* aparece en solo 11 empresas de la muestra, así que no admite pruebaestadística. Se reporta como faltante, no se fuerza un resultado.La junta escalonada, en cambio, tiene una diferencia bruta grande: menor ROA, menor ROE y mayorWACC. Falta ver si sobrevive a los controles.

5.3 Modelo multivariado de estructura de junta

In [204... FORMULA_COMPLETA = (
 "{y} ~ PctIndep + TamJunta + PctMujeresJunta + EdadJunta + dual + escalonada
 "+ logMC + DeudaActivos + C(Sector)"
)
 VARS_INTERES = [
 "PctIndep",
 "TamJunta",
 "PctMujeresJunta",
 "EdadJunta",
 "dual",
 "escalonada",
 "logMC",
]


```

resultados = {}
for y in ["ROA", "ROE", "ROIC_WACC", "WACC"]:
    cols = [
        y,
        "PctIndep",
        "TamJunta",
        "PctMujeresJunta",
        "EdadJunta",
        "dual",
        "escalonada",
        "logMC",
        "DeudaActivos",
        "Sector",
    ]
    d = dfw[cols].dropna()
    m = smf.ols(FORMULA_COMPLETA.format(y=y), data=d).fit(cov_type="HC1")
    resultados[y] = pd.Series(
        {
            v: f"{m.params[v]:+.3f}{'***' if m.pvalues[v] < 0.01 else '**' if m.pvalues[v] < 0.05 else '*'}"
            for v in VARS_INTERES
        }
    )
    resultados[y]["n"] = len(d)
    resultados[y]["R2"] = f"{m.rsquared:.3f}"

print("Todas las variables de junta compitiendo en el mismo modelo")
print("(*** p<0.01, ** p<0.05, * p<0.10)\n")
pd.DataFrame(resultados)

```

Todas las variables de junta compitiendo en el mismo modelo
 (***) p<0.01, ** p<0.05, * p<0.10)

Out[204...

	ROA	ROE	ROIC_WACC	WACC
PctIndep	-0.019	-0.133	+0.008	-0.024**
TamJunta	-0.445	-0.145	-0.006	-0.176***
PctMujeresJunta	+0.070	+0.128	+0.004	-0.029**
EdadJunta	+0.372***	+0.557**	+0.051**	-0.092***
dual	-2.191*	-4.480	-0.397**	+0.034
escalonada	-0.384	-1.195	-0.040	+0.608**
logMC	+2.720***	+7.641***	+0.326***	+0.327***
n	363	338	364	364
R2	0.167	0.169	0.133	0.384

En el modelo conjunto se confirma la asimetría:- **Ecuación del WACC:** casi todo lo que asociamos a buen gobierno reduce el costo de capital, y la junta escalonada lo aumenta. Es la ecuación con mayor poder explicativo del ejercicio.- **Ecuaciones de rentabilidad:** solo la edad promedio de la junta y la dualidad del CEO quedan significativas. La

independencia y la diversidad no aportan poder explicativo sobre ROA.- El **tamaño** (logMC) es el predictor dominante de la rentabilidad en toda especificación. El coeficiente de la edad promedio de la junta es positivo y robusto, pero no debe leerse como "juntas más viejas gestionan mejor". Es más plausible que capture madurez de la empresa: las compañías establecidas tienen juntas de más edad y rentabilidad más estable.

5.4 Prueba directa: ¿el puntaje o la estructura? Se corre el puntaje compuesto y la estructura en la misma ecuación, en la submuestra donde existen ambos, para ver quién retiene el poder explicativo.

```
In [205... for y in ["ROA", "WACC"]:
    cols = [
        y,
        "G",
        "PctIndep",
        "TamJunta",
        "escalonada",
        "logMC",
        "DeudaActivos",
        "Sector",
    ]
    d = dfw[cols].dropna()
    m = smf.ols(
        f"{y} ~ G + PctIndep + TamJunta + escalonada + logMC + DeudaActivos",
        data=d,
    ).fit(cov_type="HC1")
    print(f"--- {y} (n = {len(d)}, R2 = {m.rsquared:.3f})")
    for v in ["G", "PctIndep", "TamJunta", "escalonada", "logMC"]:
        print(f"    {v:16s} b = {m.params[v]:+9.4f}    p = {m.pvalues[v]:.3f}")
    print()
```

```
--- ROA (n = 359, R2 = 0.144)
G                b = +0.1164    p = 0.847
PctIndep         b = +0.0457    p = 0.488
TamJunta         b = -0.4989    p = 0.161
escalonada       b = -0.1543    p = 0.914
logMC            b = +2.7890    p = 0.000

--- WACC (n = 359, R2 = 0.405)
G                b = -0.6373    p = 0.000
PctIndep         b = -0.0046    p = 0.737
TamJunta         b = -0.1383    p = 0.013
escalonada       b = +0.2682    p = 0.323
logMC            b = +0.2809    p = 0.001
```

En la ecuación del WACC el puntaje compuesto **absorbe** el efecto de las variables de estructura: G queda fuertemente significativo y las demás pierden significancia. Es decir, el puntaje BESG resume información de gobierno que las variables individuales no capturan por separado. En la ecuación del ROA nada sobrevive en esta submuestra.

reducida de grandes capitalizaciones: entre empresas grandes y ya bien gobernadas, la variación de gobierno no discrimina rentabilidad.

6. Advertencias metodológicas Antes de la conclusión, tres problemas que estos datos no permiten resolver.

In [206...

```
print("1. CAUSALIDAD INVERSA")
print("    Un solo año de datos no distingue 'mejor gobierno produce rentabil")
print("    'las empresas rentables pueden costear mejor gobierno'. Se necesit")
print("    multianual con rezagos, o un cambio regulatorio exógeno.\n")

print("2. EL PUNTAJE MIDE TAMBIÉN DIVULGACIÓN")
sub = dfw[["G", "DivulgGob"]].dropna()
print(
    f"    Correlación G vs. puntaje de divulgación de gobierno: "
    f"{sub['G'].corr(sub['DivulgGob']):.3f} (n = {len(sub)})"
)
print(
    "    Parte del puntaje premia reportar, no gobernar bien. Empresas grande
)

print("3. WACC NO ES UN RESULTADO INDEPENDIENTE")
print(
    "    Bloomberg calcula el WACC a partir del beta y del spread de crédito.
)
print(
    "    grandes, estables y líquidas tienen beta menor por construcción, y e
)
print(
    "    empresas obtienen mejor puntaje de gobierno. La relación gobierno-WA
)
print("    fuerte del ejercicio y también la más expuesta a este problema.\n")

print("4. COBERTURA")
print(
    f"    Estructura de junta: {dfw['TamJunta'].notna().sum()} de {len(dfw)}
    f"({100 * dfw['TamJunta'].notna().sum() / len(dfw):.0f}%), sesgadas a gr
)
```

1. CAUSALIDAD INVERSA

Un solo año de datos no distingue 'mejor gobierno produce rentabilidad' de 'las empresas rentables pueden costear mejor gobierno'. Se necesitaría panel multianual con rezagos, o un cambio regulatorio exógeno.

2. EL PUNTAJE MIDE TAMBIÉN DIVULGACIÓN

Correlación G vs. puntaje de divulgación de gobierno: 0.767 (n = 154)
Parte del puntaje premia reportar, no gobernar bien. Empresas grandes reportan más.

3. WACC NO ES UN RESULTADO INDEPENDIENTE

Bloomberg calcula el WACC a partir del beta y del spread de crédito. Empresas grandes, estables y líquidas tienen beta menor por construcción, y esas mismas empresas obtienen mejor puntaje de gobierno. La relación gobierno-WACC es la más fuerte del ejercicio y también la más expuesta a este problema.

4. COBERTURA

Estructura de junta: 438 de 1878 empresas (23%), sesgadas a gran capitalización.

7. Respuesta a la pregunta

```
In [207... m_roa = modelo("ROA", "G", dfw)
m_roe = modelo("ROE", "G", dfw)
m_wacc = modelo("WACC", "G", dfw)
q5 = g_ok.loc[g_ok["Quintil"] == "Q5 (mejor)"]
q1 = g_ok.loc[g_ok["Quintil"] == "Q1 (peor)"]

print("=" * 70)
print("¿LAS EMPRESAS CON MEJOR GOBIERNO TIENEN MEJOR DESEMPEÑO?")
print("=" * 70)
print(
    f"Muestra: {dfw['G'].notna().sum():,} empresas, año fiscal {int(dfw['Year'])}
)
print("-" * 70)
print("Sí, en asociación, y el efecto más nítido es el costo de capital:")
print(f" WACC promedio, mejor quintil: {q5['WACC'].mean():.2f}%")
print(f" WACC promedio, peor quintil: {q1['WACC'].mean():.2f}%")
print(
    f" Brecha: {q5['WACC'].mean() - q1['WACC'].mean():.2f}%
)
print(
    f" Con controles: {m_wacc['coef']:+.3f} p.p. por punto de puntaje (p = {m_wacc['p_valor']:.2f})
)
print("-" * 70)
print("En rentabilidad la brecha bruta es grande y sobrevive a los controles")
print(
    f" ROA: Q5 = {q5['ROA'].mean():.2f}% vs Q1 = {q1['ROA'].mean():.2f}%
    f" | con controles {m_roa['coef']:+.3f} p.p./punto (p = {m_roa['p_valor']:.2f})
)
```

```

print(
    f" ROE: Q5 = {q5['ROE'].mean():.2f}% vs Q1 = {q1['ROE'].mean():.2f}%
    f" | con controles {m_roe['coef']:+.3f} p.p./punto (p = {m_roe['p_valc
    )
print("-" * 70)
print("PERO las características individuales de la junta (independencia, tam
print("diversidad) NO predicen rentabilidad al controlar por tamaño y sector
print("Solo predicen el costo de capital.")
print("=" * 70)

```

=====

¿LAS EMPRESAS CON MEJOR GOBIERNO TIENEN MEJOR DESEMPEÑO?

=====

Muestra: 1,433 empresas, año fiscal 2023

Sí, en asociación, y el efecto más nítido es el costo de capital:

WACC promedio, mejor quintil: 7.53%

WACC promedio, peor quintil: 9.78%

Brecha: -2.25 p.p.

Con controles: -0.550 p.p. por punto de puntaje (p = 0.0000)

En rentabilidad la brecha bruta es grande y sobrevive a los controles:

ROA: Q5 = 5.84% vs Q1 = 1.04% | con controles +0.882 p.p./punto (p = 0.0001)

ROE: Q5 = 20.37% vs Q1 = 5.77% | con controles +2.640 p.p./punto (p = 0.0000)

PERO las características individuales de la junta (independencia, tamaño, diversidad) NO predicen rentabilidad al controlar por tamaño y sector. Solo predicen el costo de capital.

=====

ConclusiónSí, existe asociación positiva, pero no es lo que suele afirmarse.****

1. El resultado más sólido es el costo de capital, no la rentabilidad. El WACC cae de forma monótona a lo largo de los cinco quintiles de gobierno, y la relación resiste todos los controles. Es la única regresión donde casi todas las variables de gobierno son significativas. Interpretación económica: el gobierno corporativo se paga en el precio del capital, que es exactamente donde la teoría de agencia predice que debería aparecer, al reducir el riesgo percibido de expropiación al inversionista.

2. La rentabilidad se asocia con el puntaje compuesto, no con la estructura de la junta. Un punto más de puntaje ESG de gobierno se asocia con +0,9 p.p. de ROA y +2,6 p.p. de ROE con controles. Pero al desagregar en independencia, tamaño de junta o diversidad de género, los coeficientes sobre ROA y ROE dejan de ser significativos. Las mejores prácticas de junta, medidas de una en una, no aparecen como palancas de rentabilidad en estos datos.

3. Los mecanismos de blindaje son la excepción con signo claro. La junta escalonada se asocia con menor ROE y mayor WACC, y la dualidad del CEO con menor ROA y menor

ROIC/WACC. Restar protección al gerente frente al control externo se ve peor que sumar buenas prácticas formales.4. **No se puede afirmar causalidad.** Con un corte transversal de 2023, la hipótesis de que las empresas rentables se pueden costear mejor gobierno (y mejor reporte de gobierno) es igual de compatible con los datos. Adicionalmente, el efecto del tamaño domina cualquier especificación de rentabilidad y el puntaje BESG premia parcialmente la divulgación. **Qué haría falta para responderlo de verdad:** un panel de varios años para rezagar el gobierno respecto al desempeño, retornos accionarios en lugar de rentabilidad contable, y un choque exógeno de gobierno (un cambio regulatorio, la entrada de un inversionista activista) que permita identificar el efecto causal.

8. Desempeño según puntaje ESG: buen vs. mal ESG

Hasta aquí el foco fue el pilar de gobierno. Esta sección clasifica las empresas por el **puntaje ESG total** y compara la distribución completa de cada métrica de desempeño con diagramas de caja y bigote.

Se usan dos clasificaciones, porque la conclusión no debe depender de dónde se corte:

Clasificación	Definición	Ventaja
Terciles extremos	Alto = tercio superior, Bajo = tercio inferior (se descarta el tercio medio)	Contraste más nítido entre "buen" y "mal" ESG
Corte en la mediana	Alto = sobre la mediana, Bajo = bajo la mediana	Usa toda la muestra, sin descartar observaciones

El boxplot es la herramienta correcta aquí porque muestra **mediana, dispersión y atípicos**, no solo el promedio. En estos datos la diferencia entre media y mediana es grande, y varias conclusiones cambian según cuál se mire.

```
In [208... esg_ok = dfw[dfw["ESG"].notna()].copy()

# Clasificación 1: terciles extremos
cortes = esg_ok["ESG"].quantile([1 / 3, 2 / 3])
esg_ok["Tercil"] = pd.qcut(esg_ok["ESG"], 3, labels=["Bajo ESG", "Medio", "Alto ESG"])

# Clasificación 2: corte en la mediana
mediana_esg = esg_ok["ESG"].median()
esg_ok["GrupoMediana"] = np.where(esg_ok["ESG"] >= mediana_esg, "Alto ESG", "Bajo ESG")

print(f"Empresas con puntaje ESG: {len(esg_ok):,}")
print(f"Cortes de tercil: {cortes.iloc[0]:.2f} y {cortes.iloc[1]:.2f}")
print(f"Mediana del ESG: {mediana_esg:.2f}\n")

resumen_grupos = esg_ok.groupby("Tercil", observed=True).agg(
```

```

n=("ESG", "size"),
ESG_min=("ESG", "min"),
ESG_medio=("ESG", "mean"),
ESG_max=("ESG", "max"),
logMC_medio=("logMC", "mean"),
)
resumen_grupos

```

Empresas con puntaje ESG: 1,433
 Cortes de tercil: 3.12 y 4.81
 Mediana del ESG: 3.96

Out [208...

	n	ESG_min	ESG_medio	ESG_max	logMC_medio
Tercil					
Bajo ESG	480	0.780	2.259	3.120	22.686
Medio	476	3.130	3.961	4.810	23.184
Alto ESG	477	4.820	5.702	8.470	23.836

8.1 Boxplots: alto vs. bajo ESG

Se comparan los terciles extremos. La línea de la caja es la mediana, el rombo es la media, la caja abarca el rango intercuartílico y los bigotes llegan a 1,5 veces ese rango.

Cada caja lleva anotado el valor de su mediana, que es el estadístico que se compara entre grupos con la prueba de Mann-Whitney.

In [209...

```

def etiquetar_medianas(ax, bp, formato="{:.2f}", dx=0.30, fontsize=8):
    """Escribe el valor de la mediana junto a la línea central de cada caja.
    for linea in bp["medians"]:
        x = np.mean(linea.get_xdata())
        y = linea.get_ydata()[0]
        ax.annotate(
            formato.format(y),
            xy=(x, y),
            xytext=(x + dx, y),
            va="center",
            ha="left",
            fontsize=fontsize,
            fontweight="bold",
            bbox={
                "boxstyle": "round,pad=0.15",
                "facecolor": "white",
                "edgecolor": "gray",
                "alpha": 0.85,
                "lw": 0.5,
            },
        )

```

In [210...

```

METRICAS = [
    ("ROA", "ROA (%)", "mayor es mejor"),

```

```

("ROE", "ROE (%)", "mayor es mejor"),
("ROIC_WACC", "ROIC / WACC", "mayor es mejor"),
("MargenOp", "Margen operativo (%)", "mayor es mejor"),
("WACC", "WACC (%)", "menor es mejor"),
("PB", "Price / Book", "referencia de valoración"),
]

COLOR_ALTO, COLOR_BAJO = "#55A868", "#C44E52"

fig, axes = plt.subplots(2, 3, figsize=(15, 9))
for ax, (col, etiqueta, sentido) in zip(axes.ravel(), METRICAS):
    alto = esg_ok.loc[esg_ok["Tercil"] == "Alto ESG", col].dropna()
    bajo = esg_ok.loc[esg_ok["Tercil"] == "Bajo ESG", col].dropna()

    bp = ax.boxplot(
        [bajo, alto],
        tick_labels=[f"Bajo ESG\n(n={len(bajo)})", f"Alto ESG\n(n={len(alto)"}],
        patch_artist=True,
        showmeans=True,
        widths=0.55,
        medianprops={"color": "black", "lw": 2},
        meanprops={
            "marker": "D",
            "markerfacecolor": "white",
            "markeredgecolor": "black",
            "markersize": 6,
        },
        flierprops={"marker": "o", "markersize": 3, "alpha": 0.35},
    )
    for caja, color in zip(bp["boxes"], [COLOR_BAJO, COLOR_ALTO]):
        caja.set(facecolor=color, alpha=0.65)


    etiquetar_medianas(ax, bp)
    ax.set_title(f"{etiqueta}\n({sentido})", fontsize=10)
    ax.set_ylabel(etiqueta, fontsize=9)
    ax.axhline(0, color="gray", lw=0.8, ls=":") if bajo.min() < 0 else None

    # Diferencia de medianas anotada
    dif = alto.median() - bajo.median()
    ax.text(
        0.5,
        0.02,
        f"Δ mediana = {dif:+.2f}",
        transform=ax.transAxes,
        ha="center",
        fontsize=9,
        bbox={"facecolor": "white", "alpha": 0.8, "pad": 2},
    )

fig.suptitle(
    "Desempeño por clasificación ESG (terciles extremos, variables winsoriza",
    fontsize=13,
)
fig.tight_layout()
plt.show()

```


Desempeño por clasificación ESG (terciles extremos, variables winsorizadas 1%-99%)



8.2 Pruebas estadísticas de la diferencia

Se reportan dos pruebas porque miden cosas distintas:

- **t de Welch:** compara **medias**, sensible a valores extremos incluso después de winsorizar.
- **Mann-Whitney:** compara **distribuciones** por rangos, no supone normalidad. Es la prueba adecuada para estos datos asimétricos.

```
In [211]... def comparar_grupos(datos, columna_grupo, etiqueta_alto, etiqueta_bajo, metr
        """Compara métricas de desempeño entre dos grupos con prueba t y Mann-W
        filas = []
        for col, etiqueta, _ in metricas:
            alto = datos.loc[datos[columna_grupo] == etiqueta_alto, col].dropna(
            bajo = datos.loc[datos[columna_grupo] == etiqueta_bajo, col].dropna(
            t, p_t = stats.ttest_ind(alto, bajo, equal_var=False)
            u, p_mw = stats.mannwhitneyu(alto, bajo)
            filas.append(
                {
                    "metrica": etiqueta,
                    "n_alto": len(alto),
                    "n_bajo": len(bajo),
                    "mediana_alto": alto.median(),
                    "mediana_bajo": bajo.median(),
                    "dif_medianas": alto.median() - bajo.median(),
                    "media_alto": alto.mean(),
                    "media_bajo": bajo.mean(),
                    "dif_medias": alto.mean() - bajo.mean(),
                    "p_welch": p_t,
                    "p_mannwhitney": p_mw,
                }
            )
```

```

    )
    return pd.DataFrame(filas).set_index("metrica")

print("Clasificación por TERCILES EXTREMOS (alto vs. bajo ESG)")
tabla_terciles = comparar_grupos(esg_ok, "Tercil", "Alto ESG", "Bajo ESG", M
tabla_terciles

```

Clasificación por TERCILES EXTREMOS (alto vs. bajo ESG)

	n_alto	n_bajo	mediana_alto	mediana_bajo	dif_medianas	media_alto	media_bajo
metrica							
ROA (%)	477	480	5.069	3.179	1.890	5.852	3.989
ROE (%)	451	459	13.421	11.561	1.861	19.263	17.402
ROIC / WACC	477	480	0.996	0.843	0.153	1.106	0.927
Margen operativo (%)	476	466	15.325	14.239	1.086	14.815	13.729
WACC (%)	477	480	7.654	8.496	-0.842	7.976	8.818
Price / Book	453	463	3.027	3.280	-0.253	6.050	5.797

```

In [212...] print("Clasificación por CORTE EN LA MEDIANA (robustez)")
tabla_mediana = comparar_grupos(
    esg_ok, "GrupoMediana", "Alto ESG", "Bajo ESG", METRICAS
)
tabla_mediana

```

Clasificación por CORTE EN LA MEDIANA (robustez)

	n_alto	n_bajo	mediana_alto	mediana_bajo	dif_medianas	media_alto	media_bajo
metrica							
ROA (%)	717	714	4.954	3.858	1.096	5.901	4.805
ROE (%)	673	681	13.237	11.814	1.422	19.092	17.670
ROIC / WACC	718	715	0.995	0.858	0.137	1.119	0.961
Margen operativo (%)	717	701	15.182	13.639	1.543	15.039	13.496
WACC (%)	718	715	7.736	8.355	-0.619	8.082	8.701
Price / Book	677	685	3.027	3.169	-0.142	6.125	5.983

Dos advertencias que salen de estas tablas:

- El **margen operativo** tiene diferencia de medias significativa pero diferencia de distribuciones **no** significativa (Mann-Whitney). El resultado lo produce la cola de márgenes muy negativos en el grupo de bajo ESG, no un desplazamiento general de la distribución.
- El **Price/Book** no difiere entre grupos por ninguna de las dos pruebas en términos brutos. Eso cambia al controlar por tamaño y sector, como se ve en la sección 8.5: contra pares comparables, las empresas de alto ESG cotizan a un múltiplo **menor**.

8.3 Los tres terciles: ¿la relación es monótona?

Si el ESG realmente ordena el desempeño, el tercil medio debería quedar entre los extremos.

In [213]...

```
PRINCIPALES = [
    ("ROA", "ROA (%)"),
    ("ROE", "ROE (%)"),
    ("WACC", "WACC (%)"),
    ("ROIC_WACC", "ROIC / WACC"),
]
COLORES_3 = ["#C44E52", "#DD8452", "#55A868"]
ORDEN = ["Bajo ESG", "Medio", "Alto ESG"]


fig, axes = plt.subplots(1, 4, figsize=(16, 5.5))
for ax, (col, etiqueta) in zip(axes, PRINCIPALES):
    grupos = [esg_ok.loc[esg_ok["Tercil"] == g, col].dropna() for g in ORDEN]
    bp = ax.boxplot(
        grupos,
        tick_labels=ORDEN,
        patch_artist=True,
        showmeans=True,
        widths=0.6,
        medianprops={"color": "black", "lw": 1.8},
        meanprops={
            "marker": "D",
            "markerfacecolor": "white",
            "markeredgecolor": "black",
            "markersize": 5,
        },
        flierprops={"marker": "o", "markersize": 2.5, "alpha": 0.3},
    )
    for caja, color in zip(bp["boxes"], COLORES_3):
        caja.set(facecolor=color, alpha=0.65)
    # Línea que une las medianas para ver la tendencia
    ax.plot(
        range(1, 4),
        [g.median() for g in grupos],
        color="black",
        lw=1.5,
        ls="--",
    )
```

```

        marker="o",
        markersize=4,
        alpha=0.7,
    )
    etiquetar_medianas(ax, bp, dx=0.22, fontsize=7.5)
    ax.set_xlim(0.5, 3.9)
    ax.set_title(etiqueta, fontsize=11)
    ax.tick_params(axis="x", labelrotation=20, labelsiz=9)

fig.suptitle(
    "Desempeño por tercil de puntaje ESG (línea negra = tendencia de las med",
    fontsize=13,
)
fig.tight_layout()
plt.show()

```



8.4 El problema del tamaño, otra vez

El grupo de alto ESG es sistemáticamente más grande que el de bajo ESG. Sin neutralizar el tamaño, el boxplot mide en parte "grandes vs. pequeñas", no "buen vs. mal ESG".

```

In [214...] alto_mc = esg_ok.loc[esg_ok["Tercil"] == "Alto ESG", "MCAP"].median()
bajo_mc = esg_ok.loc[esg_ok["Tercil"] == "Bajo ESG", "MCAP"].median()
print(f"Market cap mediano, alto ESG: {alto_mc:,.0f}")
print(f"Market cap mediano, bajo ESG: {bajo_mc:,.0f}")
print(f"Razón: {alto_mc / bajo_mc:.1f}x")

fig, ax = plt.subplots(figsize=(7, 5))
grupos_mc = [esg_ok.loc[esg_ok["Tercil"] == g, "logMC"].dropna() for g in OF
bp = ax.boxplot(
    grupos_mc,
    tick_labels=ORDEN,
    patch_artist=True,
    widths=0.6,
    medianprops={"color": "black", "lw": 1.8},
)
for caja, color in zip(bp["boxes"], COLORES_3):
    caja.set(facecolor=color, alpha=0.65)
etiquetar_medianas(ax, bp, dx=0.22)
ax.set_xlim(0.5, 3.9)


```

```
ax.set_ylabel("log(market cap)")
ax.set_title("El tercil de alto ESG está compuesto por empresas más grandes")
fig.tight_layout()
plt.show()
```

Market cap mediano, alto ESG: 21,512,176,448

Market cap mediano, bajo ESG: 5,658,691,531

Razón: 3.8x



Boxplots de desempeño ajustado

Solución: en lugar de graficar el desempeño crudo, se grafica el **residuo** de una regresión del desempeño contra tamaño, apalancamiento y efectos fijos de sector. El residuo es la parte del desempeño que **no** explican el tamaño ni el sector, así que la comparación entre grupos ESG queda limpia de esos dos factores.

Un residuo mediano por encima de cero significa "mejor desempeño que otras empresas de tamaño y sector comparables".

```
In [215... def residualizar(datos, y, controles=("logMC", "DeudaActivos")):
    """Devuelve el residuo de y contra los controles y efectos fijos de sect
    cols = [y, *controles, "Sector", "Tercil"]
    d = datos[cols].dropna().copy()
    formula = f"{y} ~ " + " + ".join(controles) + " + C(Sector)"
    m = smf.ols(formula, data=d).fit()
    d[f"{y}_resid"] = m.resid
    return d
```

```

fig, axes = plt.subplots(2, 3, figsize=(15, 9))
resultados_resid = []

for ax, (col, etiqueta, sentido) in zip(axes.ravel(), METRICAS):
    d = residualizar(esg_ok, col)
    grupos = [d.loc[d["Tercil"] == g, f"{col}_resid"] for g in ORDEN]

    bp = ax.boxplot(
        grupos,
        tick_labels=ORDEN,
        patch_artist=True,
        showmeans=True,
        widths=0.6,
        medianprops={"color": "black", "lw": 1.8},
        meanprops={
            "marker": "D",
            "markerfacecolor": "white",
            "markeredgecolor": "black",
            "markersize": 5,
        },
        flierprops={"marker": "o", "markersize": 2.5, "alpha": 0.3},
    )
    for caja, color in zip(bp["boxes"], COLORES_3):
        caja.set(facecolor=color, alpha=0.65)
    etiquetar_medianas(ax, bp, dx=0.22, fontsize=7.5)
    ax.set_xlim(0.5, 3.9)
    ax.axhline(0, color="black", lw=1)
    ax.set_title(f"{etiqueta} ajustado\n({sentido})", fontsize=10)
    ax.set_ylabel("Residuo")
    ax.tick_params(axis="x", labelrotation=20, labelsize=8)


    alto, bajo = grupos[2], grupos[0]
    u, p_mw = stats.mannwhitneyu(alto, bajo)
    resultados_resid.append(
        {
            "metrica": etiqueta,
            "mediana_resid_bajo": bajo.median(),
            "mediana_resid_alto": alto.median(),
            "diferencia": alto.median() - bajo.median(),
            "p_mannwhitney": p_mw,
            "n": len(d),
        }
    )
    ax.text(
        0.5,
        0.02,
        f"p = {p_mw:.4f}",
        transform=ax.transAxes,
        ha="center",
        fontsize=9,
        bbox={"facecolor": "white", "alpha": 0.8, "pad": 2},
    )

fig.suptitle(
    "Desempeño neto de tamaño, apalancamiento y sector, por tercil de ESG",
)

```

```
fig.tight_layout()
plt.show()

pd.DataFrame(resultados_resid).set_index("metrica")
```



Out [215...

	mediana_resid_bajo	mediana_resid_alto	diferencia	p_mannwhitney	n
metrica					
ROA (%)	0.408	-0.700	-1.108	0.020	1431
ROE (%)	2.156	-4.797	-6.953	0.000	1354
ROIC / WACC	0.134	-0.094	-0.228	0.031	1432
Margen operativo (%)	7.111	1.801	-5.310	0.000	1417
WACC (%)	-0.106	-0.310	-0.203	0.001	1432
Price / Book	-0.369	-2.940	-2.572	0.000	1362

El boxplot de residuos muestra las **medianas** por grupo, y ahí el grupo de alto ESG queda por debajo en rentabilidad. Eso exige cuidado: la regresión que genera el residuo ajusta **medias**, no medianas. Con distribuciones asimétricas, un grupo puede tener residuo medio cercano a cero y residuo mediano negativo al mismo tiempo.

La forma correcta de zanjar la diferencia es una prueba formal: una variable indicadora de "alto ESG" dentro de la misma regresión con controles.

```
In [216... # Residuo medio vs. mediano por tercil: la asimetría explica la aparente cor
print("Residuos por tercil de ESG (media vs. mediana)\n")
for col, etiqueta, _ in METRICAS:
    d = residualizar(esg_ok, col)
    tabla = d.groupby("Tercil", observed=True)[f"{col}_resid"].agg(
        ["mean", "median", "size"]
    )
    print(f"---- {etiqueta}")
    print(tabla.round(3).to_string(), "\n")
```

Residuos por tercil de ESG (media vs. mediana)

---- ROA (%)

	mean	median	size
Tercil			
Bajo ESG	-0.716	0.408	480
Medio	0.781	0.854	474
Alto ESG	-0.055	-0.700	477

---- ROE (%)

	mean	median	size
Tercil			
Bajo ESG	-0.307	2.156	459
Medio	1.126	-1.489	444
Alto ESG	-0.796	-4.797	451

---- ROIC / WACC

	mean	median	size
Tercil			
Bajo ESG	-0.086	0.134	480
Medio	0.116	0.100	475
Alto ESG	-0.029	-0.094	477

---- Margen operativo (%)

	mean	median	size
Tercil			
Bajo ESG	-3.446	7.111	466
Medio	1.973	5.899	475
Alto ESG	1.404	1.801	476

---- WACC (%)

	mean	median	size
Tercil			
Bajo ESG	0.338	-0.106	480
Medio	-0.103	-0.219	475
Alto ESG	-0.238	-0.310	477

---- Price / Book

	mean	median	size
Tercil			
Bajo ESG	2.115	-0.369	463
Medio	-0.568	-2.245	446
Alto ESG	-1.602	-2.940	453


```
In [217... # Prueba formal: indicadora de alto ESG en la regresión con controles
extremos = esg_ok[esg_ok["Tercil"].isin(["Alto ESG", "Bajo ESG"])].copy()
extremos["alto_esg"] = (extremos["Tercil"] == "Alto ESG").astype(int)

filas = []
for col, etiqueta, _ in METRICAS:
    d = extremos[[col, "alto_esg", "logMC", "DeudaActivos", "Sector"]].dropna()
    m = smf.ols(f"{col} ~ alto_esg + logMC + DeudaActivos + C(Sector)", data=d,
               cov_type="HC1"
    )
    filas.append(
        {
            "metrica": etiqueta,
            "n": len(d),
            "efecto_alto_ESG": m.params["alto_esg"],
            "ee": m.bse["alto_esg"],
            "p_valor": m.pvalues["alto_esg"],
            "R2": m.rsquared,
        }
    )

prueba_dummy = pd.DataFrame(filas).set_index("metrica")
print("Efecto de pertenecer al tercil de alto ESG, controlando tamaño, deuda y sector")
prueba_dummy
```

Efecto de pertenecer al tercil de alto ESG, controlando tamaño, deuda y sector:

```
Out[217...
```

	n	efecto_alto_ESG	ee	p_valor	R2
metrica					
ROA (%)	957	1.011	0.824	0.220	0.131
ROE (%)	910	-0.169	2.130	0.937	0.140
ROIC / WACC	957	0.143	0.130	0.271	0.108
Margen operativo (%)	942	6.977	3.608	0.053	0.122
WACC (%)	957	-0.764	0.154	0.000	0.269
Price / Book	916	-5.076	1.010	0.000	0.125

```
In [218... # Y el puntaje ESG como variable continua, para comparar con el pilar de gobernanza
filas = []
for col, etiqueta, _ in METRICAS:
    simple = modelo(col, "ESG", dfw, controles=(), fe_sector=False)
    completo = modelo(col, "ESG", dfw)
    filas.append(
        {
            "metrica": etiqueta,
            "n": completo["n"],
            "b_ESG_sin_controles": simple["coef"],
            "p_sin": simple["p_valor"],
            "b_ESG_con_controles": completo["coef"],
            "p_con": completo["p_valor"],
        }
    )
```

```

    }
)

comparacion_esg_g = pd.DataFrame(filas).set_index("metrica")
print("ESG total como variable continua (comparar con la tabla de la sección 5):")
comparacion_esg_g

```

ESG total como variable continua (comparar con la tabla de la sección 5):

Out[218...

	n	b_ESG_sin_controles	p_sin	b_ESG_con_controles	p_con
metrica					
ROA (%)	1431	1.231	0.000	0.473	0.028
ROE (%)	1354	2.990	0.000	0.260	0.654
ROIC / WACC	1432	0.161	0.000	0.040	0.234
Margen operativo (%)	1417	3.517	0.000	2.877	0.005
WACC (%)	1432	-0.288	0.000	-0.223	0.000
Price / Book	1362	-0.466	0.039	-1.570	0.000

8.5 Lectura de los boxplots

La brecha bruta es grande, pero casi toda es tamaño y sector. Es el resultado que cambia la conclusión respecto a lo que sugieren los primeros boxplots:

Métrica	Brecha bruta (Δ mediana)	¿Sobrevive a los controles?
ROA	+1,9 p.p. a favor de alto ESG	No ($p = 0,22$)
ROE	+1,9 p.p. a favor de alto ESG	No ($p = 0,94$)
ROIC/WACC	+0,15 a favor de alto ESG	No
Margen operativo	+1,1 p.p., no significativa por Mann-Whitney	Marginal ($p = 0,053$)
WACC	-0,84 p.p. a favor de alto ESG	Sí ($p < 0,0001$)
Price/Book	sin diferencia bruta	Sí, y en contra: -5,08 ($p < 0,0001$)

Punto por punto:

- **Rentabilidad:** las cajas de alto ESG están desplazadas hacia arriba en los boxplots crudos, pero el grupo de alto ESG tiene un market cap mediano 3,8 veces mayor. Al neutralizar tamaño y sector, la ventaja desaparece: la indicadora de alto ESG deja de ser significativa en ROA, ROE y ROIC/WACC. Lo que los primeros boxplots muestran es en buena medida "grandes vs. pequeñas", no "buen vs. mal ESG".
- **WACC:** la única ventaja de desempeño que resiste todo. El tercil de alto ESG paga unos 0,76 puntos porcentuales menos de costo de capital que el de bajo ESG con el

mismo tamaño y sector. Coincide con lo encontrado para el pilar de gobierno en la sección 5.

- **Price/Book:** en bruto las cajas se superponen, pero **al controlar por tamaño y sector las empresas de alto ESG cotizan a un múltiplo significativamente menor**. Comparadas contra pares de su mismo tamaño e industria, el mercado no les paga una prima; les paga menos.
- **Margen operativo:** el caso ambiguo. Significativo por medias, no por medianas (Mann-Whitney $p = 0,52$), y apenas al borde con controles ($p = 0,053$). Es un efecto de cola, producido por las empresas de márgenes muy negativos concentradas en el grupo de bajo ESG, no un desplazamiento del centro de la distribución. Como variable continua sí resiste (+2,88 p.p. por punto de ESG, $p = 0,005$), así que conviene reportarlo como evidencia débil y no como resultado nulo.

Por qué la mediana de los residuos parece contradecir esto: en los boxplots ajustados el grupo de alto ESG tiene residuo mediano negativo en ROA y ROE, pero residuo medio cercano a cero. La empresa típica de alto ESG rinde algo por debajo de sus pares de igual tamaño y sector, mientras que unas pocas empresas muy rentables levantan la media del grupo. Ese es el patrón que hay que reportar, y es distinto de "las empresas de alto ESG rinden mejor".

Distinción importante frente a la sección 5: el **pilar de gobierno** mantiene un efecto claro sobre la rentabilidad con controles (+0,88 p.p. de ROA y +2,64 p.p. de ROE por punto, ambos con $p < 0,001$). El **puntaje ESG total** casi lo pierde: +0,47 p.p. de ROA ($p = 0,028$) y nada en ROE ($p = 0,65$). Mezclar los pilares ambiental y social diluye la señal: lo que se asocia con rentabilidad es la parte de gobierno, no el agregado ESG.

9. Índice de calidad de la junta directiva (ICJ)

Se construye un indicador propio de calidad de junta a partir de las variables estructurales del archivo, y se contrasta contra el **BESG Governance Pillar Score** de Bloomberg. La pregunta es doble: ¿cuánto coinciden?, y ¿qué está premiando el puntaje de Bloomberg?

Componentes y dirección esperada

Componente	Variable	Dirección	Justificación
Independencia	% de directores independientes	Mayor mejor	Núcleo de la teoría de agencia: la supervisión requiere directores sin vínculo con la gerencia
Tamaño	Moderación del tamaño de junta	Cerca de la mediana mejor	Juntas muy pequeñas no supervisan, muy grandes se paralizan (Jensen, Yermack)

Componente	Variable	Dirección	Justificación
Diversidad	% de mujeres en la junta	Mayor mejor	Proxy de diversidad cognitiva y de apertura del proceso de nominación
Separación de roles	CEO no es presidente de junta	Sin dualidad mejor	Que el supervisado presida al supervisor es un conflicto estructural
Exposición al control	Junta no escalonada	Sin escalonamiento mejor	La junta escalonada blindada a la gerencia frente al mercado de control corporativo

Qué se excluye y por qué

Variable	Razón de exclusión
Poison pill	Solo 11 empresas la reportan como "Y": sin varianza utilizable
Paracaídas dorado	Dirección ambigua: puede ser blindaje o alineación en una adquisición
Edad promedio de la junta	Sin dirección normativa clara: no hay una edad "buena" de junta
Cambios de CEO en el año	Ambigua: la rotación puede indicar inestabilidad o un consejo que sí destituye
Asistencia a reuniones	Se evalúa en 9.3 y se descarta con evidencia, no a priori

Método de agregación

Cada componente continuo se convierte a **percentil** dentro de la muestra, no a valor estandarizado. El percentil es inmune a valores extremos y hace comparables variables con unidades distintas. Los binarios entran como 1 o 0. El índice es el promedio simple de los componentes disponibles, reescalado a 0-10 para que sea directamente comparable con el puntaje de Bloomberg.

Ponderación igual, a propósito. Sin un modelo estructural que justifique pesos, cualquier ponderación es arbitraria y el resultado se vuelve un artefacto de esa elección. Se exige un mínimo de 4 de 5 componentes por empresa para calcular el índice.

```
In [219... def a_percentil(s):
    """Convierte a percentil (0 a 1). Robusto a valores extremos."""
    return s.rank(pct=True)

COMPONENTES = {
    "indep": a_percentil(dfw["PctIndep"]),
    "moderacion_tam": a_percentil(-(dfw["TamJunta"] - dfw["TamJunta"].median)),
    "mujeres": a_percentil(dfw["PctMujeresJunta"]),
    "no_dualidad": 1 - dfw["dual"],
    "no_escalonada": 1 - dfw["escalonada"],
```

```

    "asistencia": a_percentil(dfw["Asistencia"]), # candidato, se evalúa en
}
comp = pd.DataFrame(COMPONENTES)

cobertura_comp = (
    comp.notna()
    .sum()
    .to_frame("empresas")
    .assign(pct_muestra=Lambda d: (100 * d["empresas"] / len(dfw)).round(1))
)
print("Cobertura de cada componente:")
print(cobertura_comp.to_string())
print(
    f"\nEmpresas con al menos 4 de 6 componentes: {(comp.notna().sum(axis=1)
)
print(
    f"Empresas con los 6 componentes:                {(comp.notna().sum(axis=1)
)

```

Cobertura de cada componente:

	empresas	pct_muestra
indep	381	20.300
moderacion_tam	438	23.300
mujeres	437	23.300
no_dualidad	442	23.500
no_escalonada	428	22.800
asistencia	390	20.800

Empresas con al menos 4 de 6 componentes: 415
 Empresas con los 6 componentes: 304

9.1 Construcción del índice

Se calcula primero una versión con los seis candidatos, para poder diagnosticar cada componente antes de fijar la versión definitiva.

```

In [220... def construir_indice(componentes, minimo=4, escala=10):
    """Promedio de los componentes disponibles, reescalado a 0-escala.

    Devuelve NaN si la empresa tiene menos de `minimo` componentes informados
    """
    disponibles = componentes.notna().sum(axis=1)
    return (componentes.mean(axis=1) * escala).where(disponibles >= minimo)

dfw["ICJ_v0"] = construir_indice(comp)

print("Índice preliminar (6 componentes):")
print(dfw["ICJ_v0"].describe().round(2).to_string())

```

```

Índice preliminar (6 componentes):
count    415.000
mean      5.540
std       1.770
min       0.290
25%       4.290
50%       5.660
75%       6.830
max       9.080

```

9.2 Diagnóstico: ¿aporta cada componente?

Un componente que no correlaciona con nada solo agrega ruido al promedio.

```

In [221]... diag = []
for nombre, serie in comp.items():
    s = pd.DataFrame({"c": serie, "G": dfw["G"]}).dropna()
    diag.append(
        {
            "componente": nombre,
            "n": len(s),
            "pearson_con_G": s["c"].corr(s["G"]),
            "spearman_con_G": s["c"].corr(s["G"], method="spearman"),
            "desv_est": serie.std(),
        }
    )
diagnostico = (
    pd.DataFrame(diag)
    .set_index("componente")
    .sort_values("spearman_con_G", ascending=False)
)
print("Correlación de cada componente con el puntaje de gobierno de Bloomberg")
diagnostico

```

Correlación de cada componente con el puntaje de gobierno de Bloomberg:

```

Out[221]...      n  pearson_con_G  spearman_con_G  desv_est
componente
indep    368         0.661         0.651     0.288
mujeres  423         0.534         0.559     0.288
no_escalonada  414         0.317         0.431     0.471
moderacion_tam  424         0.240         0.207     0.279
no_dualidad  429         0.123         0.110     0.477
asistencia  381         0.036         0.097     0.221

```

```

In [222]... # ¿Por qué la asistencia no discrimina? Su distribución está apilada en un s
print(dfw["Asistencia"].describe().round(2).to_string())
print("\nValores más frecuentes:")
print(dfw["Asistencia"].value_counts().head(5).to_string())
concentracion = (dfw["Asistencia"] == 75).mean() / dfw["Asistencia"].notna()

```

```
print(
    f"\nProporción de las observaciones informadas que valen exactamente 75:
)
```

```
count    390.000
mean      79.830
std       9.020
min       73.330
25%       75.000
50%       75.000
75%       75.000
max       100.000
```

Valores más frecuentes:

```
Asistencia
75.000    291
100.000    38
90.000     7
85.000     7
95.000     5
```

Proporción de las observaciones informadas que valen exactamente 75: 74.6%

Se descarta la asistencia. Más de la mitad de los valores informados son exactamente 75, lo que sugiere un valor por defecto o un redondeo de Bloomberg, no una medición real. Su correlación con el puntaje de gobierno es prácticamente cero y su varianza útil es mínima: como componente solo diluye la señal de los demás.

El índice definitivo queda con **cinco componentes**.

In [223...

```
comp_final = comp.drop(columns="asistencia")
dfw["ICJ"] = construir_indice(comp_final)

print(f"Empresas con ICJ calculado: {dfw['ICJ'].notna().sum()}")
print(dfw["ICJ"].describe().round(2).to_string())

fig, axes = plt.subplots(1, 2, figsize=(13, 5))
axes[0].hist(dfw["ICJ"].dropna(), bins=30, color="#4C72B0", edgecolor="white")
axes[0].axvline(
    dfw["ICJ"].mean(), color="#C44E52", lw=2, label=f"Media = {dfw['ICJ'].mean():.2f}"
)
axes[0].axvline(
    dfw["ICJ"].median(),
    color="#55A868",
    lw=2,
    ls="--",
    label=f"Mediana = {dfw['ICJ'].median():.2f}",
)
axes[0].set_title(f"Índice de calidad de junta (ICJ)  n = {dfw['ICJ'].notna().sum()}")
axes[0].set_xlabel("ICJ (0-10)")
axes[0].set_ylabel("Empresas")
axes[0].legend(fontsize=8)

sub_g = dfw.loc[dfw["ICJ"].notna(), "G"].dropna()
axes[1].hist(sub_g, bins=30, color="#DD8452", edgecolor="white")
```

```

axes[1].axvline(
    sub_g.mean(), color="#C44E52", lw=2, label=f"Media = {sub_g.mean():.2f}"
)
axes[1].set_title("Puntaje de gobierno BESG (misma submuestra)")
axes[1].set_xlabel("BESG Governance Pillar Score (0-10)")
axes[1].legend(fontsize=8)

fig.tight_layout()
plt.show()


```

Empresas con ICJ calculado: 414

```

count    414.000
mean      5.650
std       1.970
min       0.290
25%      4.320
50%      5.780
75%      7.120
max       9.090

```



9.3 Correlación con el puntaje de gobierno de Bloomberg

```

In [224...] par = dfw[["ICJ", "G", "logMC", "Sector", "Simbolo"]].dropna(subset=["ICJ",
print(f"Empresas con ICJ y puntaje BESG: {len(par)}\n")

correlaciones_icj = pd.Series(
    {
        "Pearson": par["ICJ"].corr(par["G"]),
        "Spearman": par["ICJ"].corr(par["G"], method="spearman"),
        "Kendall tau": par["ICJ"].corr(par["G"], method="kendall"),
    }
).round(3)
print(correlaciones_icj.to_frame("correlacion con G").to_string())

r = par["ICJ"].corr(par["G"])
print(
    f"\nR2 = {r**2:.3f} -> el ICJ explica el {100 * r**2:.0f}% de la varia
)

# Correlación parcial: quitando el efecto del tamaño de la empresa a ambas s
res_g = smf.ols("G ~ logMC", data=par).fit().resid
res_i = smf.ols("ICJ ~ logMC", data=par).fit().resid

```



```

print(f"Correlación parcial (neta de tamaño): {np.corrcoef(res_g, res_i)[0,
m_icj = smf.ols("G ~ ICJ", data=par).fit()
print(
    f"\nRecta ajustada: G = {m_icj.params['Intercept']:.3f} + {m_icj.params
)
m_icj_c = smf.ols("G ~ ICJ + logMC + C(Sector)", data=par).fit(cov_type="HC1
print(
    f"Con tamaño y sector: b_ICJ = {m_icj_c.params['ICJ']:.3f} "
    f"(p = {m_icj_c.pvalues['ICJ']:.4f}), R2 = {m_icj_c.rsquared:.3f}"
)

```

Empresas con ICJ y puntaje BESG: 400

	correlacion con G
Pearson	0.628
Spearman	0.674
Kendall tau	0.476

R2 = 0.394 → el ICJ explica el 39% de la varianza del puntaje BESG
 Correlación parcial (neta de tamaño): 0.612

Recta ajustada: $G = 3.817 + 0.476 * ICJ$


Con tamaño y sector: $b_{ICJ} = 0.406$ ($p = 0.0000$), $R^2 = 0.475$

```

In [225... fig, ax = plt.subplots(figsize=(11, 7))
for sector, g in par.groupby("Sector"):
    ax.scatter(g["ICJ"], g["G"], s=26, alpha=0.65, label=f"{sector} (n={len(

xs = np.linspace(par["ICJ"].min(), par["ICJ"].max(), 100)
ax.plot(
    xs,
    m_icj.params["Intercept"] + m_icj.params["ICJ"] * xs,
    color="black",
    lw=2.5,
    label=f"Ajuste: r = {r:.3f}, R2 = {r**2:.2f}",
)
ax.set_xlabel("Índice propio de calidad de junta (ICJ, 0-10)")
ax.set_ylabel("BESG Governance Pillar Score (0-10)")
ax.set_title("Índice propio vs. puntaje de gobierno de Bloomberg")
ax.legend(fontsize=8, loc="lower right")
fig.tight_layout()
plt.show()

```



9.4 Robustez: ¿depende la correlación de cómo se armó el índice?

Se prueban variantes que cambian los supuestos discutibles: la forma de agregar, el tratamiento del tamaño de junta y la exigencia de datos completos.

```
In [226... variantes = {}
variantes["Base (5 comp., percentiles)"] = dfw["ICJ"]

# Tamaño de junta con dirección monótona en vez de moderación
c_peq = comp_final.copy()
c_peq["moderacion_tam"] = a_percentil(-dfw["TamJunta"])
variantes["Junta más pequeña es mejor"] = construir_indice(c_peq)

# Agregación por z-score en lugar de percentiles
c_z = comp_final.apply(lambda s: (s - s.mean()) / s.std())
variantes["Agregación por z-score"] = construir_indice(c_z, escala=1)

# Solo empresas con los 5 componentes
variantes["Solo casos completos"] = dfw["ICJ"].where(
    comp_final.notna().sum(axis=1) == 5
)

# Incluyendo la asistencia descartada
variantes["Con asistencia (6 comp.)"] = dfw["ICJ_v0"]

# Solo las dos variables de blindaje
variantes["Solo blindaje (dualidad + escalonada)"] = construir_indice(
    comp_final[["no_dualidad", "no_escalonada"]], minimo=2
)
```

```

filas = []
for nombre, serie in variantes.items():
    s = pd.DataFrame({"i": serie, "G": dfw["G"]}).dropna()
    filas.append(
        {
            "variante": nombre,
            "n": len(s),
            "pearson": s["i"].corr(s["G"]),
            "spearman": s["i"].corr(s["G"], method="spearman"),
        }
    )

robustez = pd.DataFrame(filas).set_index("variante")
robustez

```

Out [226]...

	n	pearson	spearman
variante			
Base (5 comp., percentiles)	400	0.628	0.674
Junta más pequeña es mejor	400	0.499	0.572
Agregación por z-score	400	0.676	0.716
Solo casos completos	356	0.618	0.677
Con asistencia (6 comp.)	401	0.617	0.665
Solo blindaje (dualidad + escalonada)	390	0.286	0.360

La correlación se mantiene entre 0,50 y 0,68 en todas las variantes que usan el índice completo, así que el resultado no es un artefacto del diseño. Tres lecturas:

- **La agregación por z-score correlaciona algo mejor** que por percentiles (0,68 vs. 0,63). La diferencia es menor y va en contra de la robustez a valores extremos, así que se mantiene la versión por percentiles como base; la elección no cambia ninguna conclusión.
- Suponer que **la junta más pequeña es mejor** baja la correlación de 0,63 a 0,50. Bloomberg no premia juntas pequeñas, al contrario, como se confirma en 9.6.
- **Las dos variables de blindaje solas no bastan** ($r = 0,29$). Son binarias y de varianza limitada: el poder del índice viene de las variables continuas, sobre todo independencia y participación de mujeres en la junta.

9.5 ¿Clasifican igual a las mismas empresas?

La correlación mide asociación lineal o de rangos, pero lo que importa en la práctica es si los dos indicadores ponen a la misma empresa en el mismo grupo.

In [227]...

```

par = par.copy()
par["q_ICJ"] = pd.qcut(par["ICJ"], 5, labels=[1, 2, 3, 4, 5]).astype(int)

```

```

par["q_G"] = pd.qcut(par["G"], 5, labels=[1, 2, 3, 4, 5]).astype(int)

tabla_acuerdo = pd.crosstab(par["q_ICJ"], par["q_G"])
tabla_acuerdo.index.name = "Quintil ICJ (propio)"
tabla_acuerdo.columns.name = "Quintil G (Bloomberg)"

igual = (par["q_ICJ"] == par["q_G"]).mean()
cercano = (par["q_ICJ"] - par["q_G"]).abs().le(1).mean()
extremos = (par["q_ICJ"] - par["q_G"]).abs().ge(3).sum()

print(f"Mismo quintil en ambos indicadores: {igual:.1%}")
print(f"Dentro de un quintil de distancia: {cercano:.1%}")
print(f"Discrepancias fuertes (3+ quintiles): {extremos} empresas de {len(pa")
print(f"(el azar puro daría 20% de coincidencia exacta)\n")
tabla_acuerdo

```

Mismo quintil en ambos indicadores: 39.2%
 Dentro de un quintil de distancia: 81.8%
 Discrepancias fuertes (3+ quintiles): 16 empresas de 400
 (el azar puro daría 20% de coincidencia exacta)

Out[227...

	Quintil G (Bloomberg)				
Quintil ICJ (propio)	1	2	3	4	5
1	41	30	6	3	0
2	21	29	20	8	3
3	12	13	25	18	14
4	5	4	16	26	27
5	1	4	13	25	36

In [228...

```


fig, ax = plt.subplots(figsize=(7.5, 6))
im = ax.imshow(tabla_acuerdo, cmap="Blues")
ax.set_xticks(range(5), [f"Q{i}" for i in range(1, 6)])
ax.set_yticks(range(5), [f"Q{i}" for i in range(1, 6)])
ax.set_xlabel("Quintil del puntaje BESG de gobierno")
ax.set_ylabel("Quintil del índice propio (ICJ)")
for i in range(5):
    for j in range(5):
        v = tabla_acuerdo.iloc[i, j]
        ax.text(
            j,
            i,
            v,
            ha="center",
            va="center",
            fontsize=10,
            color="white" if v > tabla_acuerdo.values.max() * 0.6 else "black"
        )
ax.plot(
    [-0.5, 4.5], [-0.5, 4.5], color="#C44E52", lw=1.5, ls="--", label="Acuer"
)
ax.set_title(

```

```

    f"Coincidencia de clasificaciones\n{igual:.0%} en el mismo quintil, {cer
)
ax.legend(fontsize=8)
ax.grid(False)
fig.colorbar(im, ax=ax, shrink=0.8, label="Empresas")
fig.tight_layout()
plt.show()

```



```

In [229... # Empresas donde los dos indicadores más discrepan
par["brecha"] = par["q_ICJ"] - par["q_G"]
discrepantes = par.reindex(par["brecha"].abs().sort_values(ascending=False)).

print("Mejor estructura de junta de lo que sugiere el puntaje BESG (ICJ alto)
print(
    discrepantes[discrepantes["brecha"] > 0]
    .head(8)[["Simbolo", "Sector", "ICJ", "G", "q_ICJ", "q_G"]]
    .to_string(index=False)
)
print(
    "\nPeor estructura de junta de lo que sugiere el puntaje BESG (ICJ bajo,
)
print(
    discrepantes[discrepantes["brecha"] < 0]

```

```
.head(8)[["Simbolo", "Sector", "ICJ", "G", "q_ICJ", "q_G"]]  
.to_string(index=False)  
)
```

Mejor estructura de junta de lo que sugiere el puntaje BESG (ICJ alto, G bajo):

Simbolo	Sector	ICJ	G	q_ICJ	q_G
BIP	Utilities	7.674	2.987	5	1
NOMD	Consumer, Non-cyclical	6.521	4.706	4	1
CHKP	Technology	7.910	6.030	5	2
DOX	Technology	7.118	5.334	4	1
FBP	Financial	7.910	6.413	5	2
VEEV	Technology	7.619	6.404	5	2
NTES	Technology	6.556	3.873	4	1
FICO	Technology	7.910	6.398	5	2

Peor estructura de junta de lo que sugiere el puntaje BESG (ICJ bajo, G alto):

Simbolo	Sector	ICJ	G	q_ICJ	q_G
FITB	Financial	5.197	7.737	2	5
IGT	Consumer, Cyclical	3.610	7.661	1	4
MTSI	Technology	2.510	7.265	1	4
PBH	Consumer, Non-cyclical	5.223	7.778	2	5
CADE	Financial	2.818	7.677	1	4
RJF	Financial	4.953	7.941	2	5
COR	Consumer, Non-cyclical	4.969	7.421	2	4
EA	Technology	5.441	8.208	3	5

9.6 ¿Qué premia realmente el puntaje de Bloomberg?

Se regresa el puntaje BESG de gobierno contra las variables estructurales **en sus unidades originales**, para leer los coeficientes en términos interpretables.

```
In [230... cols = [  
    "G",  
    "PctIndep",  
    "TamJunta",  
    "PctMujeresJunta",  
    "dual",  
    "escalonada",  
    "logMC",  
    "Sector",  
]  
d_g = dfw[cols].dropna()  
m_estructura = smf.ols(  
    "G ~ PctIndep + TamJunta + PctMujeresJunta + dual + escalonada + logMC +  
    data=d_g,  
).fit(cov_type="HC1")  
  
tabla_g = pd.DataFrame(  
    {  
        "coeficiente": m_estructura.params,  
        "ee": m_estructura.bse,  
        "p_valor": m_estructura.pvalues,  
    })
```

```

).loc[["PctIndep", "TamJunta", "PctMujeresJunta", "dual", "escalonada", "log
print(
    f"Variable dependiente: puntaje BESG de gobierno.  n = {len(d_g)}, "
    f"R2 = {m_estructura.rsquared:.3f}\n"
)
tabla_g

```

Variable dependiente: puntaje BESG de gobierno. n = 356, R2 = 0.685

Out [230...

	coeficiente	ee	p_valor
PctIndep	0.049	0.004	0.000
TamJunta	0.118	0.028	0.000
PctMujeresJunta	0.029	0.005	0.000
dual	-0.151	0.092	0.103
escalonada	-0.563	0.103	0.000
logMC	-0.013	0.035	0.724

Tres lecturas sobre la construcción del puntaje de Bloomberg:

- **Premia juntas más grandes** (+0,12 puntos por director adicional, $p < 0,001$). Eso contradice el supuesto de moderación del ICJ y explica por qué la variante "junta más pequeña es mejor" correlaciona peor. Es una decisión metodológica de Bloomberg, no un hecho: la literatura de gobierno tiende a lo contrario.
- **Castiga con fuerza la junta escalonada** (-0,56 puntos), el coeficiente más grande del modelo.
- **El tamaño de la empresa no aporta** una vez incluida la estructura ($p = 0,72$). Es un buen resultado para el puntaje: en esta submuestra no es un simple proxy de capitalización.
- Con cinco variables estructurales y efectos fijos de sector se explica cerca del 69% de la varianza del puntaje. El resto viene de componentes que este archivo no trae: compensación ligada a desempeño, derechos de voto, políticas de auditoría.

9.7 ¿El índice propio predice desempeño?

Prueba independiente de validez: si el ICJ captura calidad real de gobierno, debería asociarse con desempeño. En la sección 5 las variables de junta **una por una** no predecían rentabilidad.

In [231...

```

filas = []
for y, etiqueta in [
    ("ROA", "ROA (%)" ),
    ("ROE", "ROE (%)" ),
    ("ROIC_WACC", "ROIC / WACC"),
    ("WACC", "WACC (%)" ),

```

```
]:
d_y = dfw[[y, "ICJ", "G", "logMC", "DeudaActivos", "Sector"]].dropna()
m_i = smf.ols(f"{y} ~ ICJ + logMC + DeudaActivos + C(Sector)", data=d_y)
cov_type="HC1"
)
m_ig = smf.ols(f"{y} ~ ICJ + G + logMC + DeudaActivos + C(Sector)", data=d_y)
cov_type="HC1"
)
filas.append(
    {
        "desempeno": etiqueta,
        "n": len(d_y),
        "b_ICJ": m_i.params["ICJ"],
        "p_ICJ": m_i.pvalues["ICJ"],
        "b_ICJ_junto_a_G": m_ig.params["ICJ"],
        "p_ICJ_junto": m_ig.pvalues["ICJ"],
        "b_G_junto_a_ICJ": m_ig.params["G"],
        "p_G_junto": m_ig.pvalues["G"],
    }
)

validez = pd.DataFrame(filas).set_index("desempeno")
print("ICJ y desempeño, controlando tamaño, deuda y sector:")
validez
```

ICJ y desempeño, controlando tamaño, deuda y sector:

	n	b_ICJ	p_ICJ	b_ICJ_junto_a_G	p_ICJ_junto	b_G_junto_a_ICJ	p_G_junto
desempeno							
ROA (%)	399	0.855	0.020	0.903	0.041	-0.120	
ROE (%)	373	1.847	0.056	1.505	0.155	0.865	
ROIC / WACC	399	0.170	0.005	0.127	0.071	0.109	
WACC (%)	399	-0.349	0.000	-0.112	0.155	-0.600	

Resultado destacado. El ICJ **sí** predice rentabilidad: +0,86 p.p. de ROA por punto de índice ($p = 0,020$), +0,17 en ROIC/WACC ($p = 0,005$) y un WACC menor (−0,35 p.p., $p < 0,001$). En ROE el efecto es del mismo signo pero queda al borde (+1,85 p.p., $p = 0,056$). Agregar las cinco variables estructurales en un índice recupera una señal que **se perdía al usarlas por separado** en la sección 5.

La explicación es de medición, no de magia: cada variable individual mide con error una parte de la calidad de gobierno. Promediarlas cancela parte de ese error y deja la señal común. Es el mismo argumento por el que se usan índices en vez de indicadores sueltos.

Esto corrige el matiz de la sección 5: la conclusión correcta no es "la estructura de junta no importa para la rentabilidad", sino "ninguna variable estructural aislada tiene poder suficiente, el conjunto sí".

Y hay un reparto de tareas entre los dos indicadores. Al meter ICJ y puntaje BESG en la misma regresión:

Desempeño	Quién retiene el efecto
ROA	El ICJ ($p = 0,041$); el puntaje BESG pierde significancia ($p = 0,79$)
WACC	El puntaje BESG ($p < 0,001$); el ICJ pierde significancia ($p = 0,16$)

La estructura de la junta es lo que se asocia con la rentabilidad, mientras que el puntaje comercial completo, con sus componentes de compensación, auditoría y derechos de voto, es lo que se asocia con el costo de capital. No son sustitutos: miden cosas distintas.

9.8 Conclusión de la sección

Correlación ICJ vs. puntaje BESG de gobierno: $r = 0,63$ (Spearman $0,67$), $R^2 = 0,39$.

Se mantiene en $0,61$ al neutralizar el tamaño de la empresa, y entre $0,50$ y $0,68$ en todas las variantes de construcción del índice completo.

Cómo interpretarlo:

- **Es una correlación alta, no un empate.** Cinco variables de estructura de junta reproducen cerca del 40% de la varianza de un puntaje comercial construido con muchos más insumos. La estructura de la junta es el esqueleto del puntaje de Bloomberg.
- **El 60% restante no es ruido, es contenido que este archivo no tiene.** Compensación ligada a desempeño, estructura de derechos de voto, políticas de auditoría y ética. Por eso los dos indicadores coinciden en el mismo quintil solo el 39% de las veces, aunque están dentro de un quintil de distancia el 82% de las veces.
- **Los dos indicadores discrepan sobre el tamaño de la junta.** El ICJ premia la moderación, Bloomberg premia juntas grandes. Es la principal diferencia metodológica entre ambos y es discutible en la dirección de Bloomberg.
- **El ICJ pasa una prueba de validez que las variables sueltas no pasaban:** predice ROA ($p = 0,020$), ROIC/WACC ($p = 0,005$) y WACC ($p < 0,001$) con controles de tamaño y sector, y roza la significancia en ROE ($p = 0,056$). Y cuando compite con el puntaje BESG, el ICJ es el que retiene el efecto sobre la rentabilidad, mientras el puntaje BESG retiene el del WACC.

Limitación que no desaparece: el ICJ se calcula para 415 empresas de 1.878, sesgadas a gran capitalización, porque son las únicas con datos de estructura de junta. La correlación aquí reportada describe grandes capitalizaciones.

10. Exportación de resultados

```
In [232...] ARCHIVO = "resultados_gobierno_desempeno.xlsx"

with pd.ExcelWriter(ARCHIVO, engine="openpyxl") as w:
    cobertura.to_excel(w, sheet_name="cobertura")
    matriz_spearman.to_excel(w, sheet_name="correlaciones")
    tabla_q.to_excel(w, sheet_name="quintiles")
    pd.DataFrame(resultados_q).to_excel(w, sheet_name="prueba_Q5_Q1", index=
    pd.DataFrame(filas).to_excel(w, sheet_name="mecanismos_blindaje", index=
    estructura.to_excel(w, sheet_name="regr_estructura", index=False)
    pd.DataFrame(resultados).to_excel(w, sheet_name="modelo_multivariado")
    tabla_terciles.to_excel(w, sheet_name="esg_terciles")
    tabla_mediana.to_excel(w, sheet_name="esg_mediana")
    pd.DataFrame(resultados_resid).to_excel(w, sheet_name="esg_ajustado", ir
    prueba_dummy.to_excel(w, sheet_name="esg_dummy_controles")
    comparacion_esg_g.to_excel(w, sheet_name="esg_continuo")
    diagnostico.to_excel(w, sheet_name="icj_componentes")
    robustez.to_excel(w, sheet_name="icj_robustez")
    tabla_acuerdo.to_excel(w, sheet_name="icj_vs_besg_quintiles")
    tabla_g.to_excel(w, sheet_name="que_premia_besg")
    validez.to_excel(w, sheet_name="icj_desempeno")
    par[["Simbolo", "Sector", "ICJ", "G", "q_ICJ", "q_G", "brecha"]].to_exce
        w, sheet_name="icj_por_empresa", index=False
    )

print(f"Resultados exportados a {ARCHIVO}")
```

Resultados exportados a resultados_gobierno_desempeno.xlsx